

Aplicación de técnicas de IA fiable en la predicción del índice de calidad de vida en personas con tratamiento oncológico mediante aprendizaje automático.

Pablo Pimàs Verge

Grado en Ingeniería Informática
Inteligencia Artificial

Dra. María Moreno de Castro
Dr. Friman Sánchez

Junio de 2025



Esta obra está sujeta a una licencia de
Reconocimiento-NoComercial [3.0 España de Creative Commons](https://creativecommons.org/licenses/by-nc/3.0/es/)

Ficha del Trabajo Final

Título del trabajo:	<i>Aplicación de técnicas de IA fiable en la predicción del índice de calidad de vida en personas con tratamiento oncológico mediante aprendizaje automático.</i>
Nombre del autor:	<i>Pablo Pimàs Verge</i>
Nombre del consultor/a:	<i>Dra. María Moreno de Castro</i>
Nombre del PRA:	<i>Dr. Friman Sánchez</i>
Fecha de entrega (mm/aaaa):	06/2025
Titulación:	<i>Grado de Ingeniería Informática</i>
Área del Trabajo Final:	<i>Inteligencia Artificial</i>
Idioma del trabajo:	<i>Castellano</i>
Palabras clave	<i>IA fiable, inteligencia artificial explicable, cuantificación de la incertidumbre, QoL, calidad de vida, PROM, EORTC QLQ-C30/C23</i>

Resumen del Trabajo (máximo 250 palabras): Este trabajo desarrolla un flujo de decisión clínica que predice la calidad de vida (QoL) de mujeres con cáncer de mama a partir de los cuestionarios EORTC QLQ-C30/C23, con el fin de priorizar intervenciones terapéuticas cuando la QoL sea mejorable.

Se utilizan 1.474 observaciones reales procedentes del ámbito hospitalario. Tras una exhaustiva depuración, los datos se dividen en entrenamiento (943), calibración (236) y prueba (295). Se comparan cinco algoritmos basados en árboles de decisión. La formulación original multiclase (QoL baja-media-alta) solo logra un F1-macro de 0,64; por ello se reformula el problema en una clasificación binaria (aceptable vs. mejorable), en la cual Random Forest alcanza un F1-macro de 0,8.

Para dotar al modelo de transparencia —requisito central del Reglamento Europeo de IA y la MDR— se aplican técnicas de explicabilidad global (Permutation Feature Importance, PDP/ICE, SHAP summary) y local (SHAP waterfall, LIME, DiCE). Estas herramientas revelan la influencia positiva de los dominios funcionales social, cognitivo y emocional; y el peso negativo de síntomas como fatiga y dolor de brazo, facilitando la supervisión humana y la auditoría posterior.

La incertidumbre se calibra mediante métodos clásicos y Predicción Conforme Venn-Abers, que aporta intervalos probabilísticos con cobertura frecuentista garantizada; su precisión se ve limitada por el reducido conjunto de calibración.

En conjunto, el estudio demuestra que, aun con un dataset modesto, es viable construir un clasificador explicable y con incertidumbre cuantificada, alineado con las exigencias regulatorias europeas, capaz de aportar valor clínico tangible.

Abstract (in English, 250 words or less):

This work develops a clinical decision-support workflow to predict the quality of life (QoL) of women with breast cancer based on the EORTC QLQ-C30/C23 questionnaires, with the aim of prioritizing therapeutic interventions when QoL is suboptimal.

It uses 1,474 real observations from hospital settings. After thorough cleaning, the data is split into training (943), calibration (236), and test (295) sets. Five decision tree-based algorithms are compared. The original multiclass formulation (low–medium–high QoL) only achieves a F1-macro of 0.64. Therefore, the problem is reformulated as a binary classification (acceptable vs. suboptimal), in which Random Forest achieves a F1-macro of 0.81.

To ensure model transparency—a core requirement of the European AI Act and MDR—both global explainability techniques (Permutation Feature Importance, PDP/ICE, SHAP summary) and local techniques (SHAP waterfall, LIME, DiCE) are applied. These tools reveal the positive influence of social, cognitive, and emotional functional domains, and the negative impact of symptoms such as fatigue and arm pain, thereby supporting human oversight and subsequent auditing.

Uncertainty is calibrated using classical methods and Venn-Abers Conformal Prediction, which provides probabilistic intervals with guaranteed frequentist coverage; however, its precision is limited by the small size of the calibration set.

Overall, the study demonstrates that—even with a modest dataset—it is feasible to build an explainable classifier with quantified uncertainty, aligned with European regulatory requirements and capable of providing tangible clinical value.

Índice

1. Introducción	8
1.1 Contexto y justificación del trabajo	8
1.2 Objetivos del trabajo	9
1.3 Enfoque y método seguido	10
1.4 Planificación del trabajo	11
1.5 Recursos	12
1.6 Breve resumen de productos obtenidos	13
1.7 Breve descripción de los capítulos de la memoria	14
1.8 Connotaciones ético-sociales	15
1.9 Diversidad y sesgos demográficos	15
1.10 Sostenibilidad y computación responsable	16
2. Análisis exploratorio de datos	17
2.1 Origen de los datos	17
2.2 Variable Objetivo, estructura y naturaleza de los datos	17
2.3 Selección de las variables	19
2.4 Dominio QLQ-C30	19
2.5 Dominio QLQ-C23	21
3. Preparación de los datos	23
4. Modelado: clasificación multiclase y binaria	25
4.1 Algoritmos basados en árboles de decisión	26
4.2 Interpretación de las predicciones (scores)	27
4.3 Métricas de evaluación	28
4.4 Umbral de decisión	29
4.5 Metodología	30
4.6 Clasificación multiclase	32
4.7 Clasificación binaria	34
5. Explicabilidad del modelo	37
5.1 Definición y necesidad	37
5.2 Permutation Feature Importance	39
5.3 Partial Dependency Plots (PDP)	41
5.4 Individual Conditional Expectation (ICE)	44
5.5 Local Interpretable Model-agnostic Explanations (LIME)	45
5.6 Diverse Counterfactual Explanations (DiCE)	47
5.7 SHapley Additive exPlanations (SHAP)	49
6. Cuantificación de la incertidumbre	53
6.1 Calibración clásica: Platt Scaling e Isotonic Regression	54
6.2 Predicción Conforme	54
6.3 Calibración del modelo y resultados	55
6.4 Explicabilidad de predicciones no confiables	62
6.5 Conclusiones	63
7. Conclusiones	64
7.1 Desarrollo	64
7.2 Alcance del objetivo	66
7.3 Limitaciones	67
7.4 Trabajo futuro	68

8. Glosario	70
9. Bibliografía	71
10. Anexos	75
10.1 Algoritmo IVAP	75
10.2 Librerías utilizadas	76
10.3 Propuesta de SI para el flujo de trabajo	79

Índice de figuras

Figura 1: Aplicación del marco CRISP-DM en el proyecto.	10
Figura 2: Diagrama de Gantt con la planificación del Trabajo.	11
Figura 3: Diagrama de aplicación del flujo del trabajo.	12
Figura 4: Distribución de la variable objetivo.	19
Figura 5: Matriz de correlación del dominio C30.	21
Figura 6: Matriz de correlación del dominio C23.	23
Figura 7: Distribución preliminar de la variable objetivo QoL	24
Figura 8: Distribución definitiva de la variable objetivo QoL	25
Figura 9: Matriz de confusión multiclase del modelo Random Forest	33
Figura 10: Comparativa de las métricas por modelo y clase	33
Figura 11: Proporción de las clases de QoL en los conjuntos de datos	34
Figura 12: Comparativa de métricas por modelo en la clasificación binaria	35
Figura 13: Ajuste del umbral de decisión de RandomForest	36
Figura 14: Matrices de confusión del modelo RandomForest antes y después	37
Figura 15: Permutation Importance aplicado al modelo RandomForest	40
Figura 16: Permutation Importance aplicado al modelo RandomForest	40
Figura 17: PDP 2-way aplicado a Random Forest	43
Figura 18: ICE de cada variable para el modelo Random Forest	45
Figura 19: Explicación LIME de la clasificación TP de RandomForest # 180	46
Figura 20: Explicación LIME de la clasificación FN de RandomForest # 271	47
Figura 21: PDP de Cognitive functioning y Fatigue	49
Figura 22: Beeswarm de valores SHAP en el conjunto de prueba.	51
Figura 23: Shapley Values para las características del caso # 180	52
Figura 24: Distribución de las probabilidades heurísticas del Random Forest	56
Figura 25: Curva de confiabilidad para Random Forest	57
Figura 26: Curvas de calibración de Random Forest, Isotonic y Platt	58
Figura 27: Intervalo de probabilidad para 30 observaciones al azar	60
Figura 28: Curva de calibración de RF + Venn-Abers unificado	60
Figura 29: Intervalos de confianza IVAP con epsilon mayor o igual a 0,1	61
Figura 30: Explicación de SHAP para una observación FN	63
Figura 31: Métricas obtenidas y técnicas de XAI y UQ aplicadas	66
Figura 32: Estructura del repositorio de código del proyecto	77
Figura 33: Diagrama de capas para un SI	80

Índice de tablas

Tabla 1: Estadísticos del dominio C30.	19
Tabla 2: Estadísticos del dominio C23.	22
Tabla 3: Hiperparámetros utilizados en los modelos	30
Tabla 4: Comparativa de los modelos en la predicción del conjunto de prueba	36
Tabla 5: Contraejemplos generados por DiCE	48
Tabla 6: Métricas obtenidas con Random Forest, RF + Isotonic y RF + Platt	58
Tabla 7: Comparativa de las métricas de RF sin calibrar y Venn-Abers	61

1. Introducción

1.1 Contexto y justificación del Trabajo

En los últimos años, los gobiernos han reconocido la importancia de orientar los sistemas sanitarios hacia un enfoque centrado en las personas. Un ejemplo de este compromiso es la encuesta de Indicadores Referidos por los Pacientes (PaRIS, por sus siglas en inglés), impulsada globalmente por la Organización para la Cooperación y el Desarrollo Económicos (OCDE), en la que España participa activamente [1].

En este contexto, la Organización Europea para la Investigación y el Tratamiento del Cáncer (EORTC, por sus siglas en inglés) ha desarrollado el cuestionario EORTC QLQ-C30 [2], que se ha posicionado como un estándar para calcular la percepción de las personas de su calidad de vida durante el tratamiento del cáncer.

La investigación emergente sobre los patrones psicofísicos, que influyen en la relación entre la experiencia existencial de las personas en tratamiento y el éxito terapéutico, está abriendo nuevas posibilidades. Liu et al. (2022) [3] exploraron este enfoque mediante algoritmos de árboles aleatorios para predecir la disminución del índice de calidad de vida (*Quality of Life*, QoL) en personas con cáncer de tiroides. Sus resultados no solo evidencian la precisión de estas técnicas en la identificación del deterioro de la calidad de vida, sino que también plantean la posibilidad de trasladar este conocimiento a la práctica clínica.

Sin embargo, una de las principales limitaciones, en la práctica clínica oncológica, es la falta de herramientas que permita convertir los datos sobre calidad de vida en acciones concretas, para mejorar el bienestar de los pacientes. Fayers y Bottomley (2002) [4] destacan la complejidad de integrar la evaluación del QoL en ensayos clínicos, señalando desafíos como el manejo de datos incompletos, la interpretación de múltiples escalas en mediciones repetidas y la variabilidad en el cumplimiento. Sin herramientas avanzadas para el análisis e integración de datos, la aplicación clínica de estos indicadores sigue siendo limitada.

Por otra parte, el Reglamento (UE) 2024/1689 sobre Inteligencia Artificial (AI Act) [5] establece criterios estrictos para el uso de IA en aplicaciones médicas, imponiendo requisitos de transparencia, seguridad y explicabilidad para que los modelos sean auditables y sus decisiones comprensibles. Además, exige mecanismos de gestión de la incertidumbre para minimizar sesgos y errores en las recomendaciones automatizadas, como se refleja en las Recomendaciones Éticas para una IA Fiable (AI HLEG, 2019) [6].

En este marco, para que los sistemas desarrollados sean adoptados en entornos clínicos reales, es imprescindible que los modelos sean fiables. Deben cumplir aspectos críticos como la explicabilidad [7] y la cuantificación de la incertidumbre [8]. La primera es fundamental para que las y los especialistas comprendan cómo un modelo llega a sus predicciones, facilitando su integración en la toma de decisiones médicas. La segunda permite evaluar la confianza en las predicciones obtenidas.

El presente trabajo se centra entonces en la creación de un sistema de predicción del QoL que no solo es preciso sino que además es explicable y confiable.

1.2 Objetivos del Trabajo

El propósito del trabajo es desarrollar un modelo de clasificación del índice QoL mediante algoritmos de aprendizaje automático supervisado. Se aplicarán herramientas de IA fiable en dos aspectos: explicabilidad para determinar la relación y los patrones subyacentes entre las variables calculadas del EORTC QLQ-C30 y el índice QoL; y cuantificación de la incertidumbre para interpretar el modelo y determinar su fiabilidad.

Para conseguirlo, se establece alcanzar los siguientes objetivos:

- A. Desarrollar un modelo de aprendizaje automático supervisado de clasificación optimizado.
- B. Estudiar el marco de referencia de IA fiable para determinar la aplicación de las herramientas apropiadas y el cumplimiento de las recomendaciones de la Unión Europea.
- C. Aplicar las herramientas de IA fiable para explicar las predicciones obtenidas y cuantificar su incertidumbre.
- D. Extraer conclusiones de los resultados obtenidos y discutir la aportación y limitaciones del modelo, con el fin de identificar la viabilidad de desarrollar herramientas de apoyo a la toma de decisiones clínicas.

El trabajo se llevará a cabo utilizando un conjunto de datos tabulares y etiquetados, compuesto por 1.717 observaciones, cuya variable objetivo es el índice de calidad de vida, representado como un valor decimal discreto. Estos datos, compartidos por Pimrapat Gebert en Mendeley Data [9], provienen de una encuesta basada en el EORTC QLQ-C30 aplicada a personas con cáncer de mama en el hospital Charité Universitätsmedizin Berlin.

Para la consecución de los objetivos se establecen las siguientes acciones:

- Realizar un análisis exploratorio de datos del conjunto a utilizar.
- Preparar los datos y generar los conjuntos de entrenamiento, prueba y calibración.
- Desarrollar y comparar modelos de clasificación basados en algoritmos de árboles de decisión único y de ensamble con técnicas de *Bootstrap Aggregating* y *Boosting*.
- Explicar los resultados obtenidos con el modelo óptimo, aplicando técnicas de *eXplainable AI* (XAI) [7].
- Cuantificar la confiabilidad del modelo mediante técnicas de calibración con Predicción Conforme [10].

1.3 Enfoque y método seguido

El trabajo utiliza una planificación basada en la cronología del Plan Docente, adoptando el ciclo iterativo del marco de desarrollo CRISP-DM [11]. La elección de esta metodología se debe a su robustez y estructura clara para gestionar el ciclo de vida de manera sistemática. Además, permite aplicar las técnicas de explicabilidad sin comprometer el flujo de desarrollo e integrar la calibración final del modelo. En la figura 1 se muestra cómo se ajustan las acciones de este trabajo a las etapas de CRISP-DM, mientras el diagrama de Gantt de la figura 2 muestra la cronología de las distintas fases, sus tareas correspondientes y las entregas que establece el Plan Docente.




Figura 1: Aplicación del marco CRISP-DM en el proyecto.

Como primera opción se consideró la adaptación de redes neuronales mediante transferencia de conocimiento. Este enfoque permitiría reutilizar modelos previamente validados y reducir el tiempo de desarrollo. Sin embargo, los conjuntos de datos en el dominio de los PROMS son tabulares y, en general, contienen solo unos miles de observaciones.

En este aspecto, Shwartz-Ziv y Armon (2021) [12] demostraron empíricamente que XGBoost supera a los modelos profundos en este tipo de conjuntos, requiriendo menos ajustes y reduciendo el tiempo de entrenamiento. Además, Grinsztajn et al. (2022) [13] evidenciaron que los modelos basados en árboles siguen siendo la mejor alternativa en conjuntos pequeños y medianos (≈ 10.000 observaciones), consolidando su eficacia en este contexto. En consecuencia, se ha optado por continuar esta línea y adoptar los modelos basados en árboles de decisión, como se ha indicado anteriormente.

Para el tratamiento de los datos y el desarrollo del modelo, se han escogido las tecnologías de código abierto en el ecosistema del lenguaje Python, dada su velocidad de implementación, y la amplia documentación disponible.




Figura 2: Diagrama de Gantt con la planificación del Trabajo.

1.4 Planificación del Trabajo

El flujo de trabajo se compone de los diferentes procesos que vienen definidos por la ciencia de datos [14] para procesos de clasificación:

- 1 Comienza con el análisis exploratorio y la preparación de los datos, seguida de la división en conjuntos de entrenamiento, prueba y calibración.
- 2 A continuación, se realiza el modelado con los algoritmos de clasificación supervisada propuestos. Se comienza con el entrenamiento de un árbol de decisión único, se estudian las métricas para interpretar los resultados y evaluar el rendimiento. Luego, se entrenan los modelos de ensamble y, para cada uno de ellos, se realiza la validación cruzada y se analizan las métricas de entrenamiento y prueba para determinar el sobreajuste.
- 3 Una vez seleccionado el modelo óptimo, se le aplican las herramientas de explicabilidad, tanto locales como globales, para analizar los resultados y estudiar el comportamiento en casos particulares.
- 4 Por último, se cuantifica la incertidumbre de los valores crudos predichos por el modelo con Predicción Conforme y los métodos clásicos.

La figura 3 muestra el diagrama de aplicación con los conjuntos de datos y los procesos que componen el flujo de trabajo.




Figura 3: Diagrama de aplicación del flujo del trabajo.

1.5 Recursos

El correcto desarrollo del proyecto requiere los recursos que se mencionan a continuación.

Hardware:

Ordenador con capacidad suficiente para entrenar modelos de machine learning (CPU de alto rendimiento y, opcionalmente, GPU o *Neural Engine*)

Software:

- Entorno de desarrollo en Python
- Librerías de machine learning Scikit-learn, XGBoost, LightGBM y CatBoost.
- Herramientas de explicabilidad SHAP, LIME, DiCE y de calibración Predicción Conforme.

Datos:

Conjunto de datos tabulares de coeficientes calculados del cuestionario EORT QLQ-C30

Documentación:

Normativa sobre IA fiable (AI Act), estudios de referencia sobre modelos de clasificación y documentación de CRISP-DM.

1.6 Breve resumen de productos obtenidos

El estudio y desarrollo del trabajo se ha realizado mediante la implementación de 5 cuadernos (Notebooks) Jupyter y un paquete de funciones auxiliares. Todos los ejecutables pueden ser consultados en el repositorio del trabajo¹, en los directorios /Fase 2 y /Fase 3. Además, se pueden consultar las versiones html estáticas de los cuadernos, con las salidas incluidas y sin necesidad de ejecutarlos nuevamente, ubicadas en el directorio /html notebooks versions.

Cuaderno 1_EDA.ipynb

Análisis exploratorio y preparación de los datos

Se abordan las tareas del análisis exploratorio de los datos y su preparación en el Marco de CRISP-DM. Primero, se realiza el análisis de los dominios C30 y C23 por separado. Luego, se estudian las correlaciones existentes entre todo el conjunto de variables. Finalmente, se realiza la preparación de la variable objetivo para la clasificación multiclase y el análisis de la mejor alternativa y la preparación para la clasificación binaria.

Cuaderno 2.1_Modelado_multiclase.ipynb

Modelado: Clasificación supervisada multiclase

Se desarrolla el modelado multiclase mediante la aplicación de los algoritmos basados en árboles de decisión. Luego, se realiza un análisis parcial de los resultados obtenidos, antes de aplicar los algoritmos más costosos computacionalmente, y se extraen las conclusiones. Se decide replantear el problema nuevamente y, en consecuencia, tomar las medidas correctoras necesarias en la fase de preparación de los datos. Para la implementación se utilizan las librerías de Scikit-Learn y XGBoost.

Cuaderno 2.2_Modelado_binario.ipynb

Modelado: Clasificación supervisada binaria

Se desarrolla el modelado binario mediante la aplicación de los algoritmos basados en árboles de decisión. Se realiza el análisis comparativo de los resultados y se selecciona el modelo con mejores prestaciones. Finalmente, se extraen las conclusiones y se exporta el modelo que se utilizará para las fases de explicabilidad y cuantificación de la incertidumbre. Para la implementación se utilizan las librerías de Scikit-Learn, XGBoost, CatBoost y LightGBM.

Cuaderno 3_Explicabilidad.ipynb

Explicabilidad del modelo

Se aplican las técnicas de explicabilidad globales y locales al modelo seleccionado en la fase de modelado binario. Todos los algoritmos aplicados son independientes al modelo: Permutation Feature Importance, Partial Dependence Plot, Individual Conditional Expectation, Local Interpretable Model-Agnostic Explanations, Diverge Counterfactual Explanations y Shapley Additive Explanations. Para la implementación se utilizan las librerías de Scikit-Learn, SHAP, LIME y DiCE.

¹ <https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial>

Cuaderno 4_Incertidumbre.ipynb

Cuantificación de la incertidumbre del modelo

Para concluir el trabajo, se realiza la calibración del modelo mediante Predicción Conforme utilizando el algoritmo Venn-Abers Conformal Prediction, con el fin de obtener las probabilidades calibradas y los intervalos de predicción del índice de calidad de vida. Se analiza la calidad de la calibración y se estudian las predicciones menos confiables, aplicando nuevamente las técnicas de explicabilidad locales anteriores.

Paquete de funciones auxiliares xaiuq_functions

Funciones en lenguaje Python para exploración, visualización, XAI y UQ

El paquete se compone de 4 módulos: exploración, visualización, explicabilidad y cuantificación de la incertidumbre. Cada uno de estos módulos encapsula las funciones utilizadas en los cuadernos, con el fin de desacoplar el código del análisis para ser reutilizable y facilitar la legibilidad de los cuadernos.

1.7 Breve descripción de los capítulos de la memoria

Capítulo 2 *Análisis exploratorio de datos*

Se presenta el conjunto de datos, el origen de su estructura, la razón de los dominios y la justificación de la selección de variables. Luego, se detalla el proceso y el resultado del análisis exploratorio.

Capítulo 3 *Preparación de los datos*

Se realiza la preparación de la variable objetivo para clasificación multiclase y binaria; y también se eliminan las observaciones no informadas.

Capítulo 4 *Modelado: clasificación multiclase y binaria*

Se detalla la metodología aplicada en la clasificación multiclase, se presenta el modelado realizado y se analizan los resultados parciales para extraer conclusiones. Posteriormente, se analiza el replanteamiento del problema de clasificación y se detallan las medidas correctivas aplicadas. Finalmente, se desarrolla la clasificación binaria y se presenta el modelado realizado. Se estudian y analizan los resultados comparativamente para seleccionar el modelo con mejor comportamiento y se extraen las conclusiones.

Capítulo 5 *Explicabilidad del modelo*

Se introduce el concepto de Inteligencia Artificial Explicada, su necesidad y una breve descripción del marco legislativo de la Unión. Luego, se discute sobre las técnicas aplicadas al modelo seleccionado realizando el estudio de los resultados obtenidos.

Capítulo 6 *Cuantificación de la incertidumbre*

Se introduce el concepto de Cuantificación de la Incertidumbre y en específico la Predicción Conforme. Luego, se analiza la metodología aplicada estudiando los resultados para obtener conclusiones del trabajo realizado. Finalmente, se analizan las

observaciones con menor confiabilidad en sus predicciones aplicando nuevamente las técnicas de explicabilidad local.

Capítulo 7 *Conclusiones del trabajo*

Se presentan las conclusiones de los resultados obtenidos, las limitaciones encontradas, las posibilidades de desarrollo y los pasos siguientes para continuar con la línea de trabajo.

Anexo

Se detallan las librerías de software utilizadas en los cuadernos desarrollados, se describe el algoritmo Venn-Abers utilizado y se presenta un breve diseño de un SI para incorporar el flujo de trabajo en una aplicación clínica.

1.8 Connotaciones ético-sociales

El presente trabajo busca favorecer a las personas bajo tratamiento de cáncer de mama, pero también permitir la extensibilidad de los métodos aplicados a otros tipos de tratamiento donde la calidad de vida de las y los pacientes se pueda ver comprometida.

El compromiso ético se refleja en velar por que los algoritmos no reproduzcan ni amplifiquen sesgos existentes —por ejemplo, derivados de diferencias demográficas o de acceso al sistema sanitario—, asegurando que las predicciones sean equitativas y no discriminen a ningún colectivo, como se explica en el siguiente apartado. De esta forma, la trazabilidad y explicabilidad del modelo son clave para que el personal sanitario y las personas bajo tratamiento comprendan y confíen en las recomendaciones automatizadas, manteniendo siempre el control humano en la toma de decisiones y respetando la autonomía de las y los pacientes.

1.9 Diversidad y sesgos demográficos

Los algoritmos de aprendizaje automático son tan justos o tan parciales como los datos con los que se entrenan [15]. Cuando dichos datos reflejan desequilibrios históricos o sociales —por ejemplo, infrarepresentación de un género o de determinados grupos étnicos en los ensayos clínicos— el modelo puede aprender patrones que perpetúan estas injusticias. En nuestro contexto clínico, esto podría traducirse en predicciones menos fiables para pacientes de ciertos orígenes geográficos o étnicos, lo que agravaría las desigualdades en el acceso al diagnóstico y al tratamiento. Por ello, es esencial evaluar no solo el rendimiento global del clasificador, sino también su comportamiento por subgrupos de género, edad o etnia, comprobando que las métricas y el error de calibración no varíen de forma injustificada entre ellos.

En el presente trabajo, los datos se encuentran anonimizados en la fuente y no utilizamos las variables sociodemográficas porque nos centramos exclusivamente en los predictores de los formularios EORTC QLQ-C30 y C23, que no incluyen datos sensibles a sesgos de tipo social, étnicos o demográficos.

1.10 Sostenibilidad y computación responsable

La publicación «Computing can help mitigate climate change but must first cease contributing to it»² señala que el sector de la computación ya representa entre el 2% y el 3% de las emisiones globales de gases de efecto invernadero, una cifra comparable a la de la industria de la aviación. A medida que los modelos de IA y los centros de datos escalan en tamaño y complejidad, el consumo energético asociado —sobre todo debido al uso intensivo de GPUs— crece de forma exponencial, arrastrando un aumento paralelo en la huella de carbono y en el uso de agua para refrigeración [16].

Para revertir esta tendencia, es imprescindible aplicar principios de *Green Computing* [17] a lo largo de todo el ciclo de vida de los sistemas: desde la elección de hardware más eficiente y la optimización del software para reducir cómputo innecesario, hasta la migración a infraestructuras alimentadas por energías renovables y la reutilización inteligente de equipos para minimizar el desperdicio electrónico (e-waste). Solo así podremos aprovechar el potencial de la inteligencia artificial como herramienta para la sostenibilidad sin sacrificar el propio equilibrio medioambiental que pretendemos preservar.

Este trabajo utiliza CodeCarbon³, para medir el consumo de electricidad de los cuadernos Jupyter y calcular la huella de carbono en emisiones de CO₂. La información se encuentra disponible en el repositorio del proyecto¹ en el directorio /carbon.

El consumo de cada ejecución completa de la serie de cuadernos en un Mac Book Pro con Apple Silicon M2 Pro y 32 GB de Ram es:

EDA:	0,000456Kwh	0,0 Kg CO ₂	
Modelado multiclase:	0,005260Kwh	0,001 Kg CO ₂	
Modelado binario:	0,002338Kwh	0,0005 Kg CO ₂	
Explicabilidad:	0,000515Kwh	0,0 Kg CO ₂	
Incertidumbre:	0,000075Kwh	0,0 Kg CO ₂	
Total:	0,008644Kwh	0,0015 Kg CO ₂	1,5 g CO ₂

Esta cifra puede parecer insignificante, sin embargo, 12 ejecuciones de la serie de 5 cuadernos toman tan solo 25 minutos y son el equivalente al consumo de una televisión LED durante una hora. Esto nos da una idea del gran impacto de la utilización de los modelos de aprendizaje automático en las emisiones de efecto invernadero.

Como medida de mitigación, en el cuaderno de modelado multiclase se evita ejecutar el entrenamiento de los modelos más costosos energéticamente con un análisis previo que justifica esta decisión.

² ACM Tech Brief (2023) <https://dl.acm.org/doi/pdf/10.1145/3483410>

³ <https://codecarbon.io/>

2. Análisis Exploratorio de Datos (EDA)

Antes de aplicar modelos predictivos, el EDA permite detectar sesgos de muestreo, comprender correlaciones entre variables clínicas y guiar las decisiones de transformación e imputación de datos. En este estudio, nuestro objetivo es:

- Identificar patrones y relaciones relevantes entre las variables y el índice de calidad de vida.
- Detectar valores atípicos y ausencias que puedan sesgar las conclusiones.
- Seleccionar las técnicas de preprocesado más adecuadas para los algoritmos basados en árboles.

El Análisis Exploratorio de Datos es una fase fundamental dentro de la metodología CRISP-DM que persigue «entender» el conjunto de datos antes de la aplicación de cualquier modelo predictivo o confirmatorio. John Tukey [18], considerado el padre del EDA, defendía que esta etapa debía servir para detectar patrones inesperados, anomalías o supuestos de modelado que podrían invalidar inferencias posteriores.

Para implementar el EDA en el trabajo, se han utilizado las librerías del stack del lenguaje Python:

- Pandas para la manipulación y exploración de los datos.
- Scikit-Learn KBinsDiscretizer para la transformación multiclase.
- Numpy para la transformación binaria y operaciones numéricas.
- Matplotlib y Seaborn para la visualización gráfica.

2.1 Origen de los datos

La naturaleza médica del problema abordado dificulta considerablemente el acceso a conjuntos de datos públicos, especialmente cuando se trata de información sensible como la relativa a los PROM. En este contexto, el conjunto de datos compartido por Pimrapat Gebert en Mendeley Data [9] resulta de gran valor para desarrollar investigaciones abiertas en esta área. El conjunto utilizado corresponde a la encuesta realizada a mujeres, en el inicio del tratamiento de cáncer de mama entre 2016 y 2021, por la Charité – Universitätsmedizin Berlin.

2.2 Variable objetivo, estructura y naturaleza de los datos

El cuestionario utilizado consta de tres dominios: datos basales sociodemográficos, formulario genérico para cáncer EORTC QLQ-C30 (C30) [19] y módulo específico para cáncer de mama EORTC QLQ-C23 (C23) [20]. Para los cuestionarios C30 y C23, el conjunto contiene los índices ya calculados de las variables, de acuerdo con las respuestas de cada participante. La variable objetivo pertenece al formulario genérico (C30) y es el índice de calidad de vida (QoL, *Quality of Life*).

El conjunto de datos no recoge las respuestas individuales, sino los índices derivados mediante las fórmulas oficiales de la EORTC. Cada variable representa un dominio funcional o sintomático que puede abarcar varias preguntas del cuestionario original.

Estas variables están expresadas como valores numéricos discretos pertenecientes al conjunto de los racionales positivos, organizados en series con intervalos regulares.

La metodología específica para el cálculo de los índices escapa al alcance del presente trabajo y puede encontrarse en la documentación de la EORTC [21]. Sin embargo, para una mejor comprensión del problema es importante conocer cómo se obtiene la variable objetivo QoL.

Cada una de las preguntas del cuestionario puede ser respondida con un valor representado en una escala. Luego, para cada una de las variables se calcula su valor bruto (*Raw Score*) a partir de la suma de los valores de cada una de las preguntas del cuestionario. En el caso de QoL las preguntas involucradas son la 29 y la 30. El cálculo del valor bruto es:

$$RS = \frac{Q_{29} + Q_{30}}{2}$$

Luego, se normaliza esta puntuación bruta a una escala estándar de 0 a 100. La fórmula depende del tipo de variable, en el caso de QoL se realiza una transformación lineal positiva por ser una escala funcional. El denominador es el rango de escala, es decir, la diferencia entre mínimo y máximo que pueden tomar las preguntas:

$$QoL = \frac{RS - 1}{6} \times 100$$

En consecuencia, si una paciente responde a las preguntas 29 y 30 con 5 y 6 respectivamente, el cálculo arroja el siguiente índice calculado:

$$RS = \frac{6 + 5}{2} = 5.5$$

$$QoL = \frac{5.5 - 1}{6} \times 100 = 75$$

De esta manera, los índices de calidad de vida no representan directamente la percepción de las personas bajo tratamiento, sino una estimación normalizada, que permite comparar pacientes en una escala común. Los valores tienen una ordenación y sentido en cuanto sus magnitudes son comparables: para cada predictor 0 puede interpretarse como nada y 100 como mucho. Esta transformación, aunque necesaria para el análisis, introduce una capa de abstracción sobre la percepción real de las pacientes.

2.3 Selección de las variables

Para este trabajo se han incluido exclusivamente los dominios C30 y C23, por ser escalas utilizadas internacionalmente y con alta capacidad de comparación entre estudios clínicos [20].

Se han descartado los datos sociodemográficos por depender de variables específicas de las entidades sanitarias y las legislaciones locales, lo que limitaría la generalización de los resultados más allá de este conjunto de datos.

2.4 Dominio QLQ-C30

El conjunto original contiene 1.727 observaciones con 15 variables correspondientes a los índices derivados del cuestionario EORTC QLQ-C30. Durante el análisis preliminar, se identificaron 249 observaciones con valores nulos en la totalidad de las variables. Por lo tanto, el conjunto depurado consta de 1.478 observaciones válidas para el análisis. En la tabla 1 se detalla la información relevante para cada una de las variables.

Por un lado, se tienen las variables relativas al funcionamiento físico, de rol, emocional, cognitivo y social de las personas durante su vida cotidiana. Estas contienen una mayor densidad en los valores altos que produce una distribución con cola a la izquierda (*skew* negativo). En líneas generales, podemos decir que las personas tienen una valoración positiva sobre su desempeño cotidiano, siendo los aspectos físicos, de rol y social los que más casos atípicos presentan; y que pueden deberse a un subgrupo relacionado con otros factores como el tipo de tratamiento.

Por otro lado, se tienen las variables relativas a los síntomas propios de la enfermedad o el tratamiento: fatiga, náuseas, dolor, disnea, insomnio, pérdida de apetito, estreñimiento y diarrea. Estas, junto con los problemas financieros producidos por la enfermedad, tienen una mayor densidad en los valores bajos con cola hacia la derecha (*skew* positivo). Este hecho podría indicar que la mayoría de las personas en tratamiento no se ve afectada por los mismos síntomas, siendo la fatiga, el dolor y el insomnio los más presentes. Mientras las náuseas, el estreñimiento y la diarrea son los más escasos. En cuanto a los problemas financieros podemos decir que solo una proporción reducida de la muestra se ha visto muy o medianamente afectada.

Tabla 1 – Información estadística del dominio C30

Variable	Tipo	Nulos	Skew	Media	Std	Min	1Q	2Q	3Q	Max
QoL	float64	249	-0.68	67.45	22.40	0.00	50.00	66.67	83.33	100.00
Physical functioning	float64	249	-1.95	88.37	17.49	6.67	86.67	93.33	100.00	100.00
Role functioning	float64	249	-2.26	88.48	23.34	0.00	83.33	100.00	100.00	100.00
Emotional functioning	float64	249	-0.46	62.04	26.90	0.00	41.67	66.67	83.33	100.00
Cognitive functioning	float64	249	-0.73	69.26	22.94	0.00	55.56	72.22	88.89	100.00
Social functioning	float64	249	-1.51	82.63	25.37	0.00	66.67	100.00	100.00	100.00

Fatigue	float64	249	0.89	27.18	25.78	0.00	0.00	22.22	44.44	100.00
Nausea and vomiting	float64	249	3.13	5.44	12.80	0.00	0.00	0.00	0.00	100.00
Pain	float64	249	1.26	21.47	26.40	0.00	0.00	16.67	33.33	100.00
Dyspnea	float64	249	1.98	12.99	24.18	0.00	0.00	0.00	33.33	100.00
Insomnia	float64	249	0.64	32.79	33.34	0.00	0.00	33.33	66.67	100.00
Appetite loss	float64	249	1.95	13.08	24.93	0.00	0.00	0.00	33.33	100.00
Constipation	float64	249	2.90	6.41	16.81	0.00	0.00	0.00	0.00	100.00
Diarrhea	float64	249	2.66	8.16	19.34	0.00	0.00	0.00	0.00	100.00
Financial difficulties	float64	249	2.92	7.89	20.73	0.00	0.00	0.00	0.00	100.00

En cuanto a la variable objetivo, en la figura 4 la distribución acumulada de la variable muestra como aproximadamente un 20% de las personas obtiene un índice medio-bajo (<50) y el 70% restante medio-alto (>60). En los valores más altos encontramos que casi un 40% obtiene valores altos (>80). En líneas generales, se puede decir que las personas de la muestra poseen una calidad de vida —durante el tratamiento— buena o muy buena, mientras para un $\approx 15\%$ es mala o muy mala; en el sentido del concepto «bueno» como cercano a la normalidad que se puede esperar en este contexto. En la distribución, se puede observar la separación en intervalos de 8,33 en 13 clases, como consecuencia de la forma de calcular el índice QoL explicado anteriormente.




Figura 4: Distribución de la variable objetivo (QoL)

La matriz de correlaciones de la figura 5, muestra claramente los dos tipos de relaciones que hemos encontrado en el análisis univariable. Por un lado, los predictores funcionales con una relación directa. Por otro, los predictores relativos a la sintomatología con una relación inversa. Es decir, a valores altos, los primeros inciden positivamente sobre la calidad de vida, mientras los segundos lo hacen negativamente.

Se puede ver también que dentro de estos conjuntos diametralmente opuestos existen fuertes correlaciones. En el caso de los aspectos cognitivos y emocionales, ambos predictores proporcionan prácticamente la misma información; mientras el dolor y la fatiga tienen una fuerte correlación opuesta con todas las variables de funcionamiento. Además, se identifica un subgrupo dentro de los síntomas formado por dolor, disnea,

insomnio y pérdida de apetito que tienen una correlación alta con fatiga y que podría representar una relación directamente proporcional.

En todos los casos, valores altos de una variable funcional o bajos de una sintomática, no es condición suficiente para obtener una calidad de vida elevada, como se ha reflejado con la presencia de estos valores en los niveles más bajos de QoL. Sin embargo, todas ellas presentan una mayor o menor tolerancia por parte de las personas para obtener un nivel de calidad de vida alto. Para el caso de los síntomas de diarrea, disnea y dolor esta tolerancia disminuye con respecto al resto. Mientras que el funcionamiento físico, de rol y social son los más valorados para tener una calidad de vida máxima.




Figura 5: Matriz de correlaciones del dominio C30

2.5 Dominio QLQ-C23

El conjunto específico para el cáncer de mama también contiene las 1.727 observaciones iniciales, pero con las 8 variables correspondientes a los índices derivados del cuestionario EORTC QLQ-C23. Al igual que en el caso anterior, se identificaron las 249 observaciones con valores nulos en la totalidad de las variables, con el añadido de otras 4 observaciones sin informar. Como resultado, el conjunto depurado consta de 1.473 observaciones válidas para el análisis. En la tabla 2 se detalla la información relevante para cada una de las variables.

Además de las observaciones con valores faltantes en todas las variables, el conjunto presenta dos casos particulares: Sexual enjoyment con 817 nulos y Upset by hair loss

con 1214 nulos. En la primera, la muestra indica que posiblemente se produce un sesgo en la variable hacia valores altos, dado que son los mayoritariamente informados. En la segunda, los valores faltantes podrían deberse a personas que no han experimentado este efecto secundario de los tratamientos más agresivos. Sin embargo, no tenemos forma de comprobarlo con los datos disponibles.

En ambos casos existen indicativos de que no se trata de valores faltantes aleatorios, sino todo lo contrario: responden a una ausencia MNAR (*Missing Not At Random*) [22] donde imputar correctamente es teóricamente más complejo y menos efectivo. Esta casuística es algo frecuente en los conjuntos de datos reales donde, por ejemplo, una persona no responde a una pregunta sensible en una encuesta o incluso no responde a verdad por razones personales. Le Morvan et al (2025) [23] han comprobado empíricamente que en estos casos la imputación puede ser perjudicial para el rendimiento predictivo. Considerando además que el porcentaje de valores nulos supera el 70 % en ambas variables, se ha optado por eliminarlas del conjunto, al no aportar información útil para la tarea de clasificación.

Tabla 2 – Información estadística del dominio C23

Variable	Tipo	Nulos	Skew	Media	Std	Min	1Q	2Q	3Q	Max
Arm symptoms	float64	253	1.32	16.32	15.48	0.00	4.76	14.29	23.81	85.71
Body image	float64	253	-1.94	85.27	21.61	0.00	77.08	91.67	100.00	100.00
Breast symptoms	float64	253	1.52	17.24	20.78	0.00	0.00	8.33	25.00	100.00
Future perspective	float64	253	0.09	45.23	34.90	0.00	0.00	33.33	66.67	100.00
Sexual enjoyment	float64	817	-0.51	73.44	26.10	0.00	66.67	66.67	100.00	100.00
Sexual functioning	float64	253	0.34	36.17	29.71	0.00	0.00	33.33	66.67	100.00
Systemic therapy side effects	float64	253	1.83	12.45	19.23	0.00	0.00	0.00	22.22	100.00
Upset by hair loss	float64	1214	0.71	34.44	33.48	0.00	0.00	33.33	66.67	100.00

Al igual que en el conjunto C30, podemos encontrar dos tipos de variables muy marcados. Por un lado, las referidas a síntomas de la enfermedad o el tratamiento: Arm symptoms, Breast symptoms, Systemic therapy side effects y Upset by hair loss. Todas ellas mantienen una relación inversa respecto a la variable objetivo: cuanto más crecen, más decrece la calidad de vida. Por otro lado, las referidas a aspectos positivos: Body image, Future perspective, Sexual enjoyment y Sexual functioning, con una relación directa con QoL, es decir, cuanto más crecen sus valores, más crece la calidad de vida.

En cuanto a las correlaciones internas del conjunto, la figura 6 muestra como ambos grupos presentan claramente correlaciones diametralmente opuestas entre ellos y similares en su interior. En el caso de las variables donde sus valores altos inciden positivamente en QoL, vemos una correlación más alta en la imagen corporal y las perspectivas de futuro. Por el contrario, en las que lo hacen negativamente los síntomas en el brazo son los que presentan una correlación negativa más marcada. También es destacable la correlación, relativamente alta, entre las dos variables del aspecto sexual, la cual podemos intuir que no es mayor debido al sesgo que presenta Sexual enjoyment. En general, se aprecian valores cercanos a cero que indican poca linealidad o redundancia entre la información que aportan los atributos.

En conclusión, ambos conjuntos se complementan eficazmente, ya que el C23 es una ampliación del C30 y no generan redundancias en la información que aporta cada uno. En ambos encontramos los mismos tipos de variables de síntomas y aspectos de funcionamiento, perspectivas e imagen propia, las primeras con una incidencia negativa en la calidad de vida, mientras las segundas la influyen positivamente.




Figura 6: Matriz de correlaciones del dominio C23

3. Preparación de los datos

En la metodología CRISP-DM, la fase de Data Preparation incluye todas las tareas necesarias para limpiar, dar formato y estructurar el dataset de modo que sea apto para el modelado. En este proyecto, la preparación de los datos abarca:

- Eliminación de variables y registros incompletos
- Transformación de la variable objetivo en multiclase
- Transformación de la variable objetivo en binaria

Los valores faltantes que pertenecen a observaciones sin informar en todas las variables se eliminaron por no aportar información relevante, mientras que las columnas Sexual enjoyment y Upset by hair loss se eliminaron debido a la imposibilidad de imputar eficazmente y al alto porcentaje de nulos.

En cuanto a la variable objetivo QoL, en una primera iteración del ciclo se realizó una transformación en tres clases: 0: Calidad de vida baja, 1: Calidad de vida media y 2: Calidad de vida alta.

Esta decisión se fundamenta tanto en la distribución observada de la variable —con mayor densidad en los valores altos— como en la necesidad de aportar una interpretación clínica relevante, que facilite la posterior aplicación del modelo en contextos médicos reales. La categorización permite, además, evaluar de forma más clara el comportamiento del modelo frente a los distintos niveles de calidad de vida por rangos, con especial atención a la franja media-baja, por su relación con el objetivo de determinar las personas a las cuales es necesario mejorar su situación durante el tratamiento.

Para ello, se aplicó una discretización uniforme mediante el algoritmo KBinsDiscretizer de Scikit-Learn con 3 categorías (*bins*) y codificación ordinal. De este modo, la transformación no comprime las clases de acuerdo a la distribución de la variable y realiza una agrupación por rangos iguales. La figura 7 muestra la distribución resultante, donde se aprecia un desbalanceo de la clase baja con respecto a las otras dos.




Figura 7: Distribución preliminar de la variable objetivo QoL posterior a la transformación en 3 clases

Como se verá en la fase de modelado, esta transformación no fue apropiada para conseguir los objetivos. La dificultad en separar correctamente las clases contiguas —por todos los modelos aplicados—, pero en especial las clases baja y media, imposibilitó obtener resultados aceptables en la clasificación.

En esta situación, el desafío ha sido determinar cuál es el límite apropiado para dividir ambas clases. Por un lado, se tienen las observaciones de las personas con una calidad de vida que se busca mejorar. Por otro lado, se tienen las personas con un nivel de calidad de vida que se puede estimar como aceptable. No debemos olvidar que estamos hablando siempre desde el punto de vista de la normalidad que se puede tener en este tipo de tratamientos.

En consecuencia, una división 50-50 dejaría fuera de la clase mejorable a las personas con índices medios que podrían tener un amplio margen de mejora. Al observar la distribución y proporciones de casos de QoL en la figura 4, se puede ver que a partir de un valor cercano a los 2 tercios de la escala (66,7), se produce un salto significativo del $\approx 37\%$ al $\approx 57\%$ de las personas. Es decir, poco más de la mitad de las pacientes tiene un QoL inferior a 75, que podría considerarse como mejorable. Por lo tanto, se ha tomado

este valor como el mínimo aceptable de calidad de vida y todos los valores inferiores como mejorables, para realizar la transformación con las clases: 1: mejorable, sobre la cual se focaliza la clasificación, y 0: aceptable.

$$y = \begin{cases} 1, & \text{si } QoL \leq 75 \text{ (mejorable)} \\ 0, & \text{si } QoL > 75 \text{ (aceptable)} \end{cases}$$

La figura 8 muestra la distribución de QoL resultante, donde se aprecian las dos clases muy balanceadas: 52,2% mejorable y 47,8% aceptable. De este modo, del total de 1.474 observaciones 770 tienen un QoL mejorable (clase 1), mientras 704 tienen un QoL aceptable (clase 0).




Figura 8: Distribución definitiva de la variable objetivo QoL posterior a la transformación binaria

Con estas tareas completadas, se ha limpiado el conjunto, sin columnas incompletas y con la variable objetivo preparada para la clasificación multiclase y binaria. La división en conjuntos de entrenamiento, calibración y prueba se ha realizado directamente en la sección de modelado, para satisfacer las necesidades de cada clasificación.

4. Modelado: clasificación multiclase y binaria

En CRISP-DM, la fase de modelado utiliza el dataset preparado para entrenar, validar y comparar distintas técnicas de aprendizaje supervisado. Nuestro objetivo es predecir la clase de una paciente (nivel de QoL) empleando algoritmos basados en árboles de decisión simples y en ensamble.

El aprendizaje supervisado es un paradigma del aprendizaje automático en el que se construye un modelo $f : X \rightarrow Y$ a partir de un conjunto de entrenamiento formado por pares (x_i, y_i) , donde X es el espacio de características y Y el espacio de etiquetas [24]. El objetivo es que, una vez entrenado, el modelo generalice adecuadamente a nuevos casos no vistos.

En el contexto de clasificación, la variable objetivo Y asume valores discretos, correspondiendo cada uno a una clase. Según el número de categorías, distinguimos:

Clasificación binaria: El conjunto de etiquetas es $Y \in \{0,1\}$

Clasificación multiclase: El conjunto de etiquetas se amplía a $Y \in \{0,1,\dots,K-1\}$.

Existen dos enfoques clásicos para convertir problemas multiclase en múltiples problemas binarios:

One-vs-Rest (OvR): para cada clase k , se entrena un clasificador binario que separa la clase k de todas las demás [25].

One-vs-One (OvO): para cada par de clases (i, j) , se entrena un clasificador que las diferencia, combinándose luego sus predicciones mediante reglas de votación.

La elección entre técnicas nativas o descomposición OvR/OvO depende de la eficiencia computacional y la distinción entre clases adyacentes. Los algoritmos que hemos utilizado extienden de forma nativa su criterio de partición a multiclase, por lo tanto se ha optado por delegarles esta tarea.

El modelado se ha desarrollado en dos iteraciones. En un primer momento se aplicaron modelos de clasificación multiclase y se realizó un análisis parcial de los resultados. Luego, se tomaron medidas correctivas con una nueva preparación de la variable objetivo para realizar la clasificación binaria.

4.1 Algoritmos basados en árboles de decisión

Los árboles de decisión [26] son clasificadores que particionan recursivamente el espacio de características X en regiones homogéneas respecto a la variable objetivo Y . Cada nodo interno aplica una prueba sobre una característica y cada hoja asigna la clase mayoritaria de las muestras que en ella caen. Las particiones se eligen de forma codiciosa (*greedy*), maximizando en cada paso la ganancia de información (entropía) o la reducción de impureza de Gini [27]. Los árboles individuales tienen la ventaja de ser intrínsecamente interpretables y manejar variables mixtas sin preprocesado complejo, pero suelen presentar alta varianza, lo que les hace sensibles al sobreajuste.

Para mejorar la estabilidad y el rendimiento predictivo, se utilizan ensambles de árboles mediante dos paradigmas principales:

Bagging (Bootstrap Aggregating) [28]

Cada modelo de un Random Forest se entrena sobre un muestreo con reemplazo del conjunto de datos original (Bootstrap). Además, en cada nodo se considera un subconjunto aleatorio de características para evaluar posibles particiones. La predicción final se obtiene aglomerando (votación mayoritaria) o promediando las salidas de todos los árboles. Esta doble aleatorización reduce la correlación entre árboles y disminuye la varianza del modelo sin aumentar significativamente el sesgo.

Boosting

Bajo el esquema de Gradient Boosting [29], se ajusta secuencialmente una colección de árboles débiles. Siguiendo el esquema de Friedman (2001) [30], en cada iteración t el nuevo árbol aprende a predecir los pseudo-residuos de la función de pérdida (por ejemplo, log-loss en clasificación binaria). Es decir, el gradiente negativo de la pérdida respecto a la predicción actual $F_{t-1}(x)$. La actualización del modelo se realiza como:

$$F_t(x) = F_{t-1}(x) + \nu h_t(x), [30]$$

Cada árbol t aporta una pequeña corrección $h_t(x)$ al score acumulado, escalada por la tasa de aprendizaje ν , de modo que el modelo controla el tamaño de cada paso.

4.2 Interpretación de las predicciones (scores)

Los modelos de Scikit-Learn —DecisionTree y RandomForest— y los que utilizan APIs similares como XGBoost, CatBoost y LightGBM exponen el método `predict_proba` [31] [32] que asigna una probabilidad heurística o puntuación cruda a cada clase. En el caso del RandomForest, cada árbol t asigna la muestra x a una hoja que contiene $n_k^{(t)}$ instancias de la clase k y $N^{(t)}$ instancias en total. De esta manera, el puntaje crudo (*raw score*) de ese árbol para la clase k en dicha muestra se calcula como el cociente:

$$s_k^{(t)}(x) = \frac{n_k^{(t)}}{N^{(t)}}$$

El método devuelve el promedio de estos puntajes sobre todos los estimadores T para cada muestra x :

$$\hat{s}_k(x) = \frac{1}{T} \sum_{t=1}^T s_k^{(t)}(x)$$

En el caso de los modelos con técnicas de Boosting, como cada nuevo árbol se entrena para corregir los errores residuales del conjunto anterior optimizando la función de pérdida, la suma de las correcciones genera un score crudo $\hat{s}(x)$ tras T iteraciones:

$$\hat{s}(x) = \sum_{t=1}^T \nu h_t(x). \quad ^4$$

⁴ La descripción se basa en la definición de Breiman (2001) [27] que Scikit-Learn implementa en el código fuente de `predict_proba` [32].

Luego, todos los modelos transforman internamente estos puntajes en valores entre 0 y 1 de forma que sumen 1, *pero sin tener en cuenta la prevalencia de cada etiqueta en el dataset*. Por lo tanto, las salidas de `predict_proba` requieren un paso de calibración si se quiere interpretarlas como probabilidades reales [33]. Esta calibración se aborda con mayor detalle en el capítulo 6: cuantificación de la incertidumbre.

4.3 Métricas de evaluación

Para cuantificar el rendimiento de los clasificadores empleamos múltiples métricas que capturan distintos aspectos del rendimiento. El objetivo de la optimización es minimizar los dos tipos de errores: falsos positivos (etiquetar como mejorable un QoL aceptable) y falsos negativos (etiquetar como aceptable un QoL que es mejorable). No existe una métrica específica que resuelva todos los errores, se debe realizar una negociación entre minimizar uno u otro dependiendo de la naturaleza del problema.

En nuestro caso, las métricas [34] que controlamos en el proceso nos dan información acerca del comportamiento del modelo bajo distintos aspectos:

Exactitud (*Accuracy*)

Indica la proporción de predicciones correctas respecto al total de instancias. Es decir, cuantas predicciones correctas ha realizado el modelo. Puede empujar el modelo a predecir siempre la clase mayoritaria en conjuntos muy desbalanceados.

Precisión (*Precision*)

Mide la fiabilidad de las predicciones positivas; es decir, el porcentaje de instancias clasificadas como mejorable que realmente lo son.

Sensibilidad (*Recall*)

Refleja la capacidad de detectar todos los casos positivos; crucial para no dejar fuera pacientes con QoL mejorable.

F1-score

Es la media armónica entre precisión y recall, que sintetiza el equilibrio entre ambos. El promedio del F1-score de cada clase es el F1-macro. Lo utilizamos para optimizar la búsqueda del mejor predictor porque garantiza que todas las clases aporten por igual al resultado global.

ROC-AUC

El área bajo la curva ROC evalúa la capacidad de distinguir entre clases para todos los umbrales.

Analizando más de cerca el F1-score, decimos que dado un problema con C clases, el puntaje de la clase i viene dado por la relación entre precisión (P_i) y sensibilidad (R_i):

$$P_i = \frac{TP_i}{TP_i + FP_i}$$

La precisión es la proporción de verdaderos positivos respecto al total de casos positivos predichos.

$$R_i = \frac{TP_i}{TP_i + FN_i}$$

Mientras, la sensibilidad es la proporción de los verdaderos positivos respecto al total de casos positivos reales.

$$F1_i = 2 \times \frac{P_i \times R_i}{P_i + R_i}$$

El F1 score es la media armónica que expresa el equilibrio entre ambas.

Finalmente, el F1 macro es la media aritmética de estos puntajes (scores):

$$F1_{macro} = \frac{1}{C} \sum_{i=1}^C F1_i$$

Con ello garantizamos que cada clase, tanto en clasificación multiclase como binaria, aporte el mismo peso al resultado global, independientemente de su tamaño en el conjunto de validación.

4.4 Umbral de decisión

Como hemos visto, los modelos basados en árboles asignan una puntuación continua o probabilidad heurística, pero no una etiqueta discreta. Para obtener la predicción final binaria con $\hat{y} \in \{0,1\}$, se fija un umbral de decisión τ —por defecto 0.5— de modo que:

$$\hat{y} = \begin{cases} 1 & \text{si } p(\text{clase} = 1 \mid x) \geq \tau, \\ 0 & \text{en caso contrario.} \end{cases}$$

Sin embargo, cuando las clases están desbalanceadas, el umbral estándar tiende a favorecer la clase mayoritaria. En nuestro caso clínico, un falso negativo (clasificar como «aceptable» un QoL que es «mejorable») significa perder la oportunidad de mejorar la calidad de vida de una paciente. Por ello, en la clasificación se escoge τ para maximizar la sensibilidad de la clase prioritaria; por ejemplo, optimizando un F1 score que penalice más los falsos negativos [35][36].

La selección de τ se realiza explorando diferentes valores. En nuestro caso, con el conjunto de validación obtenemos las puntuaciones crudas $\hat{s}(x)$ para la clase «mejorable». Luego, barremos un conjunto de valores $\tau \in [0,1]$ equiespaciados (por ejemplo, 30 puntos) y para cada τ obtenemos las predicciones binarias $\hat{y} = (\hat{s} \geq \tau)$. Finalmente, elegimos τ^* como aquel que maximiza el F1 Macro. Este proceso garantiza un punto de funcionamiento donde el modelo logra el mejor compromiso global entre precisión y recall de ambas clases, acorde con nuestros objetivos clínicos y de equilibrio de errores.

4.5 Metodología

La búsqueda del modelo óptimo en el espacio de hiperparámetros es un factor determinante para obtener resultados aceptables, ya que un mismo algoritmo puede variar considerablemente su comportamiento dependiendo de las variables que maneje en su ejecución. Para esta tarea se utilizan distintas técnicas, entre las cuales hemos utilizado la grilla de búsqueda GridSearchCV de la librería Scikit-Learn, con validación cruzada estratificada a 5 hojas y el F1 macro como métrica de validación. El algoritmo se encarga de entrenar los modelos para cada una de las combinaciones y de particionar los datos para la validación cruzada.

Los hiperparámetros actúan como mecanismos de control sobre el comportamiento del modelo, regulando su complejidad para garantizar una buena capacidad de generalización. Por ejemplo, parámetros como la profundidad máxima de un árbol o el número mínimo de muestras por hoja limitan hasta qué punto el modelo puede ajustarse a los pequeños vaivenes del conjunto de entrenamiento, reduciendo así el riesgo de sobreajuste. De manera similar, tasas de aprendizaje, factores de submuestreo o coeficientes de regularización (L1/L2) en algoritmos de boosting modulan el tamaño de cada actualización y penalizan estructuras excesivamente complejas, promoviendo soluciones más estables y robustas. En conjunto, el ajuste correcto de los hiperparámetros permite encontrar el punto óptimo en el equilibrio complejidad-generalización: un modelo lo suficientemente expresivo para capturar patrones relevantes, pero lo bastante simple para no memorizar el ruido de los datos. La tabla 3 muestra una descripción de los hiperparámetros utilizados para cada modelo sin repetir los que se utilizan en más de uno.

Tabla 3: Hiperparámetros utilizados en los modelos

Modelo	Hiperparámetro	Descripción
	criterion	Determina la función que el árbol utiliza para medir la «calidad» de cada división: Gini busca particiones que minimicen la impureza definida como la probabilidad de clasificar mal una instancia al asignarla aleatoriamente según la distribución de clases en el nodo. Entropy maximiza la reducción de entropía, lo que equivale a elegir cortes que aporten mayor riqueza informativa.

DecisionTree	splitter	Especifica la estrategia de búsqueda de la mejor división en cada nodo: Best examina todas las características disponibles y elige la división que aporta la máxima mejora según el criterion. Random elige aleatoriamente una de las divisiones suficientemente buenas, reduciendo tiempo de búsqueda a costa de mayor aleatoriedad en el árbol.
	max_depth	Determina la profundidad máxima que puede alcanzar el árbol. Un valor entero limita explícitamente la altura, ayudando a controlar el sobreajuste. Mientras None permite crecer el árbol hasta que todas las hojas sean puras o hasta que no haya más divisiones posibles.
	min_samples_split	Número mínimo de instancias que debe tener un nodo para poder dividirse. Valores enteros evitan que el árbol genere divisiones a partir de muy pocas muestras, lo cual reduce la complejidad y la tendencia al sobreajuste.
	class_weight	Permite asignar pesos diferentes a cada clase para contrarrestar el desequilibrio. Un ajuste como {0:3, 1:1, 2:1} penaliza tres veces más los errores sobre la clase 0 (baja calidad de vida), incentivando al modelo a reducir falsos negativos en esa categoría crítica.
	min_samples_leaf	Número mínimo de instancias que debe contener cada hoja tras una división. Ajustes como 13, 14 o 15 garantizan que cada hoja tenga al menos esas muestras, suavizando las particiones finales y evitando hojas con muy baja representatividad.
RandomForest	n_estimators	Número de árboles en el bosque. Valores medios-altos (200, 225, 250) equilibran la reducción de varianza (con más árboles la votación es más estable) con tiempo de cómputo.
	ccp_alpha	Parámetro de Cost-Complexity Pruning (poda post-entrenamiento). Un valor positivo (0.008, 0.009, 0.01) introduce una penalización a la complejidad de cada árbol, eliminando ramas que aportan poco a la mejora de la pureza y reduciendo el sobreajuste en el conjunto de ensamble.
XGBoost	min_child_weight	Controla el peso mínimo (suma de instancias) que debe tener un nodo para permitir una división. Valores más altos (4, 6, 10) evitan que el árbol aproxime patrones demasiado específicos en regiones con pocas muestras, reduciendo el sobreajuste.
	subsample	Fracción de muestras de entrenamiento utilizadas para entrenar cada árbol. Al emplear sólo un 50 % o 80 % de las instancias (None equivale a usar el 100 %), introducimos aleatoriedad en los datos de cada paso de boosting, lo que mejora la generalización al evitar que cada iteración vea siempre el mismo conjunto completo.
	learning_rate	Factor multiplicativo entre 0 y 1 que escalona la contribución de cada nuevo árbol al score acumulado. Tasas más bajas implican pasos más prudentes en la optimización de la log-loss, lo cual suele requerir más árboles pero conduce a soluciones más estables y menos propensas a sobreajuste.

	reg_alpha (regularización L_1)	Penalización de la suma de los valores absolutos de las contribuciones de hoja. Un reg_alpha en torno a 0.11–0.13 empuja muchos pesos de hoja hacia cero, favoreciendo modelos más dispersos y con menor varianza.
	reg_lambda (regularización L_2)	Penalización de la suma de los cuadrados de las contribuciones de hoja. Al ajustar reg_lambda entre 0.11 y 0.13, limitamos la magnitud de los pesos de hoja de manera continua, suavizando la función final y ayudando a controlar la complejidad global del modelo.
CatBoost	bagging_temperature	Controla la aleatorización en el muestreo de instancias para cada árbol. Un valor alto (1) genera mayor diversidad en los subsamples, mientras 0 equivale a un muestreo determinista, buscando estabilidad en cada iteración.
	rsm	Random subspace method: fracción de características utilizadas en cada iteración de boosting (0.5, 1.0). Valores menores introducen aleatoriedad en las columnas, reduciendo correlación entre árboles y varianza del ensamble.
LightGBM	min_split_gain	Ganancia mínima en la función loss requerida para aceptar una división (0.09). Esta «poda previa» impide divisiones que aporten mejoras insignificantes, simplificando la estructura global del conjunto de árboles.

4.6 Clasificación multiclase

En la clasificación multiclase se ha realizado el entrenamiento y test de tres modelos: DecisionTree, RandomForest y XGBoost. El objetivo ha sido evaluar el comportamiento de los tres tipos de algoritmos antes de entrenar los modelos computacionalmente más costosos como CatBoost y LightGBM. Luego, se han comparado los resultados y se han extraído las conclusiones.

En el caso del árbol de decisión, el rendimiento es claramente más limitado. Presenta una estructura simple y poco profunda, lo que restringe su capacidad de capturar relaciones complejas en los datos. En la comparación entre el entrenamiento y la prueba, el modelo muestra la mayor caída de f1-score en la clase baja (de 0.47 a 0.36), evidenciando su baja capacidad de generalización, especialmente frente al solapamiento entre clases.

El modelo XGBoost, por su parte, ha mostrado un rendimiento más estable en las clases media y alta, con valores de f1-score elevados y consistentes. Sin embargo, en la clase baja solo logra clasificar correctamente 14 de 33 observaciones, lo que representa una sensibilidad muy pobre de 0,42. A pesar de su complejidad y técnicas avanzadas como la regularización y el submuestreo, el modelo sigue sin resolver de forma efectiva la separación de los casos minoritarios.

El modelo Random Forest presenta mejoras sustanciales con respecto al árbol de decisión simple y se mantiene en la línea del XGBoost. En la clase baja obtiene una sensibilidad de 0,52 clasificando correctamente 17 de las 33 observaciones con una precisión de solo el 0,47. Si bien es el modelo con mejor comportamiento, al igual que los anteriores presenta grandes dificultades para separar las clases baja y media. La figura 9

evidencia este problema en la matriz de confusión, donde puede verse como casi la mitad de las observaciones con clase baja son clasificadas erróneamente.




Figura 9: Matriz de confusión multiclase del modelo Random Forest

La figura 10 muestra la comparativa de las métricas obtenidas por los tres modelos en cada una de las clases de QoL, donde se observa claramente los pobres resultados obtenidos en la clase minoritaria. En líneas generales, los tres modelos enfrentan una limitación compartida: la dificultad para separar correctamente la clase baja, lo que sugiere la necesidad de explorar nuevos planteamientos del problema con los datos disponibles.

Los resultados obtenidos evidencian que abordar la predicción del índice de calidad de vida como un problema de clasificación multiclase no resulta eficaz, dada la complejidad y el solapamiento de los patrones presentes en los datos. Por tanto, ha sido necesario replantear el enfoque para poder avanzar hacia el objetivo final.




Figura 10: Comparativa de las métricas por modelo y clase en la clasificación multiclase

Desde una perspectiva orientada a mejorar la calidad de vida de las personas bajo tratamiento, cabe preguntarse cuál es la frontera significativa que debemos establecer entre una calidad de vida aceptable y una que puede ser objeto de mejora. Si el propósito es identificar a las pacientes cuyo estado debe ser intervenido, tiene sentido unificar las clases media y baja bajo una categoría común «mejorable», reservando la

clase aceptable para aquellos casos con una calidad de vida claramente positiva. Este cambio transforma el problema en una clasificación binaria más alineada con la finalidad práctica del sistema.

De este modo, se ha redefinido el etiquetado de los datos para representar únicamente dos categorías: aceptable y mejorable. Este nuevo enfoque permite no solo simplificar la tarea de clasificación, sino también incorporar técnicas específicas como el ajuste de umbral de decisión, orientadas a optimizar la detección de los casos más relevantes: aquellos que requieren mejora.

En conclusión, el tratamiento multiclase no ha ofrecido una capacidad predictiva suficientemente robusta para alcanzar los objetivos propuestos. A partir de ahora, el modelado se centrará en una clasificación binaria, más adecuada para detectar situaciones donde la calidad de vida de los pacientes puede y debe ser mejorada.

4.7 Clasificación binaria

En la clasificación binaria el problema se aborda con la variable objetivo transformada en dos clases: 0 aceptable y 1 mejorable. En el modelado se han utilizado los algoritmos: DecisionTree, RandomForest, XGBoost, CatBoost y LightGBM.

Para la división de los conjuntos de entrenamiento y prueba se ha aplicado una proporción de 80-20 con estratificación para asegurar que las clases de la variable objetivo se distribuyan uniformemente en todos los conjuntos. Con el fin de cuantificar la incertidumbre del modelo en la próxima etapa, se ha reservado un subconjunto con el 20% del conjunto de entrenamiento, ya que el modelo no debe conocerlos durante esta fase. De esta manera, la división ha sido de 64-16-20 para entrenamiento, calibración, y prueba respectivamente. La figura 11 muestra la distribución de la variable objetivo en todos los conjuntos: del 1.474 total de observaciones, 236 se utilizan para la calibración, 295 para las pruebas y 943 para el entrenamiento.

La estrategia y metodología seguida son las mismas que en la primera iteración del modelado con la clasificación multiclase. Sin embargo, esta iteración binaria incorpora una etapa adicional de optimización del umbral de decisión. En lugar de mantener el umbral por defecto (0.5), se analiza el comportamiento de cada modelo en función de diferentes métricas para determinar un punto de equilibrio con relevancia para el problema.




Figura 11: Proporción de las clases de QoL en los conjuntos de datos

El modelado arrojó resultados con una paridad muy alta en todos los modelos, para todas las métricas. La figura 12 muestra la comparativa de las métricas obtenidas para cada modelo con el umbral de decisión optimizado. Resulta evidente la igualdad de prestaciones y es de destacar el buen comportamiento del algoritmo DecisionTree, que obtiene la mejor precisión a pesar de ser el modelo más simple. Es uno de los que mejor reconoce la clase mejorable con 132 casos de 154, es decir, un recall de 0,86 luego de ajustar el umbral de decisión. Sin embargo, su mal comportamiento en la clase aceptable, debido a la gran cantidad de falsos negativos que genera no lo hacen viable.

Dada la igualdad encontrada, es necesario estudiar las pequeñas diferencias para seleccionar el modelo con mejores resultados orientados a cumplir el objetivo del problema. En todos los casos hemos obtenido modelos robustos con baja variabilidad en la validación cruzada y de una cierta complejidad para obtener capacidad discriminativa equilibrando el *overfitting*. La tabla 4 muestra una comparativa detallada de las características más importantes de cada modelo.

Los algoritmos de *Boosting* no aportan mejoras significativas que compensen su alto costo computacional y, a excepción de LightGBM, no mejoran la clasificación de la clase mejorable del modelo simple y del modelo de ensamble.

En nuestro caso clínico la métrica más crítica es la sensibilidad, pues un falso negativo— es decir, clasificar como «aceptable» un QoL que en realidad es «mejorable»— supone perder la oportunidad de intervenir y mejorar la calidad de vida de una paciente. Por ello decidimos ajustar el umbral de decisión y seleccionar el modelo que maximiza el *recall* sobre la clase mejorable, de modo que la mayor proporción posible de pacientes con necesidad real de ayuda sea correctamente identificada, y asumiendo un aumento «tolerable» en falsos positivos. De esta forma priorizamos la detección de los casos mejorables sobre la precisión de la predicción.




Figura 12: Comparativa de métricas por modelo en la clasificación binaria

En este contexto, los modelos que obtienen un mejor comportamiento son el RandomForest y el XGBoost, con un F1 score de 0,82 y 0,81 respectivamente en la clase

mejorable para los modelos ajustados al umbral de decisión respectivamente. Sin embargo, se obtienen resultados ligeramente más equilibrados con el modelo Random Forest en cuanto a métricas, con una ROC-AUC de 0,88.

Tabla 4: Comparativa de los modelos en la predicción del conjunto de prueba (ajustados al umbral)

Modelo	Max Depth	Árboles	Precision Clase 1	Recall Clase 1	F1 macro	ROC AUC	Umbral	Brier Score	Log Loss
DecisionTree	11	1	0.68	0.86	0.71	0.81	0.32	0.18	1.54
RandomForest	11	150	0.80	0.84	0.81	0.88	0.42	0.14	0.45
XGBoost	7	100	0.78	0.86	0.79	0.86	0.37	0.15	0.46
CatBoost	7	100	0.77	0.86	0.79	0.87	0.34	0.15	0.45
LGBM	6	100	0.79	0.84	0.80	0.87	0.35	0.15	0.46

En este contexto tan ajustado, el algoritmo RandomForest al obtener el mejor equilibrio entre precisión y sensibilidad para la clase crítica «mejorable», se traduce en un mayor número de pacientes potencialmente beneficiados correctamente detectados, sin ejercer una saturación del sistema por la cantidad de pacientes con un QoL aceptable clasificados como mejorables (falsos positivos). Además, es el modelo con una mejor calibración en sus valores crudos, aunque con muy poca diferencia con respecto a los modelos *Boosting*, con un Brier score de 0.14 y una Log Loss de 0.45. En consecuencia, elegimos RandomForest como modelo final, ajustando el umbral de decisión ($\tau = 0,42$) para maximizar la detección de casos mejorables y limitar los falsos positivos.

El ajuste del umbral en el modelo RandomForest de la figura 13 demuestra con claridad la «negociación» inherente al proceso de optimización: al reducir el umbral a 0.423, el modelo logra detectar un mayor número de verdaderos positivos (TP), pero a costa de incrementar notablemente los falsos positivos (FP). Esta compensación es evidente en la distribución de errores a ambos lados del umbral, que nos permite estimar dinámicamente la matriz de confusión desplazando el límite de decisión. Es decir, podemos identificar con claridad cómo se desplazan los errores en función del umbral y ofrecer una herramienta clave para decidir, en función del contexto clínico, si priorizar sensibilidad o especificidad.




Figura 13: Ajuste del umbral de decisión de RandomForest para el conjunto de prueba

En la figura 14 pueden compararse las matrices de confusión resultantes para el umbral óptimo antes y después del ajuste. La matriz ajustada confirma el leve aumento de falsos positivos (FP), lo que constituye el coste previsible de mejorar la sensibilidad hacia la

clase mejorable. El número de verdaderos positivos (TP) aumenta de 119 a 130, y los falsos negativos (FN) se reducen a 24, lo que representa una leve mejora en la identificación de personas con calidad de vida mejorable.




Figura 14: Matrices de confusión del modelo RandomForest antes y después del ajuste del umbral de decisión

En conjunto, se concluye que la clasificación binaria desarrollada presenta un rendimiento sólido, aunque no se puede considerar óptima en cuanto a la cantidad de errores que definitivamente presentan todos los modelos. Es probable que la complejidad del conjunto de datos no permita superar el límite de clasificación alcanzado —muy similar en todos los modelos— y sea necesario enriquecer el conjunto con nuevas observaciones para estudiar posibles mejoras en el tratamiento.

En cuanto al modelo óptimo a seleccionar, el algoritmo Random Forest ha demostrado una mejor capacidad para clasificar correctamente la clase mejorable, alineándose con los objetivos del presente trabajo. Además, su relativa simplicidad y bajo coste computacional lo posicionan como una opción preferente frente a modelos más complejos, como los algoritmos de *Boosting*, que no han aportado mejoras significativas.

5. Explicabilidad del modelo

Una vez elegido el modelo resulta imprescindible desvelar su lógica interna. La explicabilidad confirma que el clasificador se basa en patrones clínicos plausibles y no en correlaciones espurias, y proporciona la trazabilidad necesaria para auditar cada predicción. Para ello combinamos técnicas globales y locales, lo que revela tanto la contribución media de cada variable como las razones de cada decisión individual. Este nivel de transparencia no solo fortalece la confianza de los profesionales, sino que cumple con el artículo 13 del AI Act [4] al ofrecer información comprensible sobre los factores que influyen en el resultado.

5.1 Definición y necesidad

La explicabilidad (o interpretabilidad) se refiere a la capacidad de un modelo para exponer los factores y procesos internos que le llevan a emitir una determinada predicción. En dominios críticos como la salud, no basta con conocer el grado de acierto

de un clasificador: es imprescindible entender «por qué» y «cómo» se toma cada decisión, de forma que los especialistas puedan juzgar su coherencia clínica y detectar posibles sesgos o atajos algorítmicos.

Si bien los términos interpretabilidad y explicabilidad suelen utilizarse indistintamente, aluden a diferentes realidades:

La interpretabilidad hace referencia a los modelos llamados transparentes (*glass-box*): su arquitectura, parámetros y reglas de decisión son directamente comprensibles para una persona experta. Árboles poco profundos o regresiones lineales constituyen ejemplos de este tipo; la explicación está incorporada de forma intrínseca en la propia forma funcional del modelo. Estos métodos ante-hoc siempre son dependientes del modelo (*model-specific*), ya que dependen de la estructura del modelo para poder acceder a ella.

La explicabilidad, en cambio, se aplica cuando el modelo es opaco (*black-box*) u oscila en una complejidad que impide la lectura directa de su lógica interna, es el caso de las redes neuronales profundas o los ensamblajes extensos, como el RandomForest seleccionado durante el modelado. Aquí la transparencia se obtiene post-hoc mediante técnicas externas capaces de aproximar —sin alterar— el razonamiento subyacente. Al tratarse de algoritmos externos al modelo, estos métodos suelen ser independientes del mismo (*model-agnostic*), aunque no siempre es así.

Para satisfacer la necesidad de explicabilidad, las técnicas utilizadas se suelen agrupar por el alcance de la explicación:

Métodos globales:

Describen la lógica general del modelo y la importancia media de cada variable en el conjunto completo de datos. En este trabajo aplicamos los siguientes:

Permutation Feature Importance: estima la pérdida de rendimiento al desordenar cada atributo.

Partial Dependence Plots (PDP): visualizan cómo varía la predicción cuando una característica cambia, manteniendo las demás fijas.

SHAP summary/global values: proporcionan la contribución media y la dispersión de cada variable.

Métodos locales:

Se centran en una única observación y explican la contribución concreta de sus atributos a la salida del modelo. En este trabajo aplicamos los siguientes:

LIME: ajusta un clasificador interpretable alrededor del punto de interés y muestra los pesos locales.

SHAP instance values: asignan créditos positivos o negativos a cada característica para esa predicción.

Individual Conditional Expectation (ICE) — traza la trayectoria de la predicción de la instancia al variar una variable mientras las demás permanecen constantes.

DiCE (Diverse Counterfactual Explanations): genera múltiples contraejemplos que cambian el resultado del modelo, mostrando qué ajustes mínimos en las características producirían una clasificación distinta.

Esta combinación de perspectivas globales y locales permite verificar que el modelo RandomForest seleccionado basa sus decisiones en patrones clínicamente plausibles — por ejemplo, fatiga elevada y dolor intenso reduciendo el QoL— en lugar de correlaciones espurias presentes solo en el conjunto de entrenamiento.

5.2 Permutation Feature Importance

La importancia de variables por permutación evalúa de forma agnóstica el impacto individual de cada característica sobre el rendimiento del modelo. Consiste en medir la caída en la métrica de evaluación (en este caso, f1-score) al alterar aleatoriamente los valores de cada variable, rompiendo así su relación con la variable objetivo. Cuanto mayor es la pérdida de rendimiento, mayor es la relevancia de la variable.

En este análisis se ha aplicado el algoritmo `permutation_importance` de Scikit-Learn sobre el modelo final de Random Forest con el conjunto de prueba. La figura 15 presenta la importancia de las variables por permutación, desglosada por tipo clínico.

Social functioning, Fatigue, Cognitive functioning y Physical functioning son las variables más importantes según el análisis de permutación: al barajar cualquiera de ellas, el F1-macro del modelo disminuye entre 1 y 2,5 puntos porcentuales, lo que indica que el clasificador depende en gran medida de esas cuatro características para discriminar las clases. En cambio, Dyspnea, Future perspective y Systemic therapy side effects muestran un valor negativo en la gráfica, lo que significa que al permutar sus valores el F1-macro no empeora e incluso puede mejorar ligeramente; esto sugiere que esas variables aportan ruido o sobreajuste en nuestro conjunto de datos. El resto de los atributos aparece con barras muy cercanas a cero, lo que implica que permutarlos apenas afecta al desempeño: el modelo prácticamente no los está utilizando o los tiene muy poco en cuenta para tomar decisiones.

Este resultado concuerda con la evidencia clínica: Fayers & Bottomley (2002) [4] muestran que el apoyo social percibido y la capacidad de mantener las actividades cognitivas cotidianas son predictores significativos de la calidad de vida durante el tratamiento, incluso tras controlar otros factores. En síntesis, el modelo capta que los aspectos funcionales sociales, cognitivos y físicos aportan información exclusiva sobre el QoL que no puede explicarse solo por la carga sintomática excepto la fatiga [37].

Comparar la relevancia de cada predictor en el conjunto de entrenamiento frente al de prueba permite estimar hasta qué punto el modelo se apoya en señales estables y generalizables. Cuando la pérdida de rendimiento provocada por permutar una variable es similar en ambos conjuntos, podemos inferir que su influencia no depende del muestreo y, por tanto, resulta robusta para casos inéditos. Por el contrario, discrepancias marcadas —una gran importancia en entrenamiento que se diluye en prueba, o viceversa

— actúan como indicadores tempranos de sobreajuste, redundancia o sensibilidad excesiva a la composición de la muestra.




Figura 15: Permutation Importance aplicado al modelo RandomForest

La figura 16 muestra como el modelo se apoya de forma estable en los funcionamientos social y cognitivo, además del síntoma de fatiga, ya que las cajas se solapan y ambas medianas son positivas aunque la dispersión en entrenamiento es algo superior. Además, los síntomas del brazo presenta la caja más ancha de toda la gráfica en prueba (variabilidad elevada, con mediana en el cero) y un desplazamiento positivo en entrenamiento. El modelo la utiliza, pero su influencia fluctúa considerablemente según el caso. Este hecho revela una fuerte dependencia del modelo respecto a este síntoma durante el entrenamiento que no se replica en el muestreo de prueba; posible señal de sobreajuste o colinealidad.




Figura 16: Permutation Importance aplicado al modelo RandomForest: entrenamiento vs prueba

Para el resto de variables, en general la dispersión es menor en entrenamiento y es mucho más estrecha en prueba, lo que sugiere una contribución contingente a la muestra y poca robustez.

En síntesis, los cinco predictores más influyentes mantienen una importancia homogénea entre entrenamiento y prueba, lo que respalda su papel como rasgos verdaderamente generales. Arm symptoms y Sexual functioning muestran importancias sensibles al muestreo: el modelo puede beneficiarse de ellos, pero su fiabilidad clínica exige precaución. Para el resto de variables, la mayoría de las sintomáticas muestran una importancia inestable o irrelevante. Este panorama sugiere que el modelo capta la calidad de vida principalmente a través de los dominios de funcionamiento, fatiga y, en menor medida, de un pequeño conjunto de síntomas frecuentes. El resto aporta información redundante o ruidosa y podría estudiarse la eliminación o el agrupamiento sin comprometer la capacidad predictiva global y reducir el riesgo de sobreajuste. Sin embargo, esta simplificación clínica debe ser estudiada por los expertos de salud en la materia. Además, es conveniente estudiar la importancia con un conjunto de datos más amplio para garantizar que la baja trascendencia no se debe a la falta de robustez estadística.

5.3 Partial Dependence Plots (PDP)

Los Partial Dependence Plots (PDP) [38] ilustran la variación media de la salida del modelo cuando se modifica una sola característica —o un par de ellas— mientras todas las demás permanecen ancladas en sus valores originales. A diferencia de los métodos de importancia que cuantifican cuánto pesa un predictor, los PDP indican cómo influye: evidencian relaciones monótonas, saturaciones, umbrales o incluso efectos no lineales que un modelo puede capturar de forma implícita.

En la práctica, el algoritmo recorre una malla de valores posibles de la variable x_j y para cada punto la sustituye en todas las observaciones, vuelve a predecir y promedia la respuesta. El resultado es la función parcial:

$$\hat{f}_j(z) = \frac{1}{n} \sum_{i=1}^n \hat{f}(z, x_{i,-j}) \quad [30]$$

que refleja el cambio esperado en la probabilidad de pertenecer a la clase mejorable cuando $x_j = z$.

De este modo, los gráficos pueden interpretarse de la siguiente forma:

- Una curva ascendente indica que valores altos de la variable empujan al modelo hacia la clase mejorable,
- Una curva descendente señala el efecto contrario,
- Tramos planos revelan rangos donde la característica es irrelevante,
- Pendientes abruptas o codos marcan umbrales clínicos potenciales.

En este caso, los predictores de funcionamiento describen una curva descendiente suave: cuanto peor es la puntuación de funcionamiento (valores crecientes hacia la izquierda del eje x), mayor probabilidad asigna el modelo a la clase «mejorable». El efecto se intensifica en Cognitive y, sobre todo, Social functioning, donde el descenso se acentúa a partir de valores < 60, señalando un umbral a partir del cual la calidad de vida se degrada con rapidez. Esta información respalda el conocimiento que se ha obtenido mediante el EDA, donde se ha visto que los valores altos de QoL se concentran en valores superiores a 60 para el caso de Emotional, Cognitive y Social Functioning.

Por otro lado, para los predictores sintomáticos la relación es la inversa: a mayor severidad del síntoma (valor alto), la estimación de pertenencia a «mejorable» crece. En Fatigue y Arm symptoms el incremento es casi lineal hasta estabilizarse por encima de 70–80 puntos, lo que sugiere que estos síntomas son determinantes ya desde niveles moderados.

Algunos predictores (Diarrhea, Constipation, Financial difficulties, Breast symptoms) muestran líneas prácticamente planas, revelando que, dentro del rango observado, permutarlos apenas altera la probabilidad prevista. Constituyen, por tanto, factores secundarios para este modelo concreto.

Por último, Body image exhibe una meseta positiva que se revierte de forma acusada cuando la puntuación cae por debajo de ~60, indicando un punto crítico a partir del cual la percepción corporal influye de manera desproporcionada en el deterioro del QoL.

En conjunto, los PDP refrendan la coherencia médica del Random Forest: el deterioro de la función social y cognitiva, junto con síntomas cardinales como fatiga y dolor, son los factores principales de la predicción, mientras que los restantes actúan solo como moduladores.

Estos perfiles univariantes, sin embargo, no evidencian interacciones clínicamente plausibles como los PDP bidimensionales (2-way), que ilustran cómo la combinación de dos predictores puede reforzar o atenuar el QoL más allá del efecto aislado de cada variable, desvelando umbrales y sinergias que orientan mejor las intervenciones de mejora. La figura 17 muestra los PDP de las 4 combinaciones analizadas entre las variables con mayor importancia.

Cognitive functioning y Emotional functioning

El PDP refleja que la puntuación cruda (PC) de predicción mejorable disminuye notablemente cuando ambos niveles de funcionamiento —cognitivo y emocional— son altos. En el cuadrante superior derecho (valores altos en ambas variables), la PC cae por debajo de 0.5, indicando buena calidad de vida según el modelo.

En cambio, en la zona inferior izquierda (valores bajos de ambas variables), la PC alcanza el 0.7, lo que sugiere que la combinación de deterioro cognitivo y emocional decrementa claramente el QoL percibido. La transición se observa alrededor del valor 70 en Cognitive functioning, donde el modelo pasa suavemente de una alta a una baja PC predicha, incluso manteniendo estable Emotional functioning.

Esta interacción sugiere que el modelo penaliza especialmente los déficits simultáneos en ambos dominios, lo cual es coherente.

Fatigue y Physical functioning

Se observa un patrón claro: a medida que aumenta la fatiga y el funcionamiento físico es inferior a ≈ 70 , la PC predicha de calidad de vida mejorable aumenta progresivamente, superando el umbral de 0.7 cuando la fatiga alcanza valores superiores a 60. En contraste, cuando el funcionamiento físico es alto (por encima de 90) y la fatiga es baja (inferior a 20), la PC cae por debajo de 0.5, indicando una predicción más favorable. Otro rasgo destacable es que a partir de valores superiores a 20 para la fatiga la PC de mejorable es alta, sin importar cuan bueno sea el funcionamiento cognitivo. Este hecho da una idea clara de la importancia de la fatiga para el modelo.


El Random Forest parece responder de forma aditiva y coherente clínicamente, penalizando ambas dimensiones por separado, pero amplificando el efecto cuando coexisten, con mucha mayor incidencia en la fatiga.

Arm symptoms y Body image

El modelo muestra un cambio brusco en la PC predicha cuando los síntomas en el brazo superan un umbral de aproximadamente 10. A partir de ese punto, especialmente en combinación con una valoración baja de la imagen corporal (Body image < 80), la PC de predicción positiva se incrementa significativamente. Similar al caso anterior con la fatiga, Arm symptoms tiene una incidencia muy fuerte a partir de ≈ 20 sin importar cuan grande sea Body.

Esto sugiere una interacción clara entre afectación física y percepción corporal, donde el impacto en la calidad de vida se amplifica si ambos factores están comprometidos. Sin embargo, solo valores muy altos de Body image y muy bajos de Arm symptoms permiten un QoL aceptable.

Gráficos PDP (2-way) por par de variables



Role functioning y Social functioning

La PC predicha de calidad de vida mejorable es más alta cuando los niveles de Social functioning se encuentran por debajo de 80, independientemente del valor de Role functioning. Sin embargo, cuando ambas variables presentan valores altos (zona superior derecha), la PC disminuye progresivamente hasta caer por debajo de 0.52.

El modelo penaliza con mayor intensidad la afectación social, y amplifica este efecto si además hay limitaciones en el rol funcional. El cambio más pronunciado ocurre en Social functioning alrededor de 70–80, lo que sugiere un umbral crítico a partir del cual la predicción mejora notablemente.

5.4 Individual Conditional Expectation (ICE)

Los gráficos de ICE desagregan el efecto de una característica a nivel de observación. Para cada paciente se recalcula la predicción mientras la variable de interés recorre todo su rango y el resto de variables permanecen fijas; el resultado es una curva específica por individuo. Al superponer todas las curvas se obtiene un abanico que revela:

Efectos promedio y dispersión.

La envolvente de las curvas reproduce el PDP, pero la anchura del abanico muestra cuánta variabilidad hay alrededor de ese efecto medio.

Subgrupos con respuestas divergentes.

Pendientes que cambian de signo o bandas claramente separadas indican perfiles clínicos cuya reacción a la variable difiere sustancialmente del resto: un indicio de interacciones latentes o de sesgo por confusión.

Observaciones atípicas.

Curvas que se alejan bruscamente del patrón común señalan pacientes cuya combinación de características hace que el modelo se comporte de forma inusual; son candidatas a revisión clínica o a técnicas de explicabilidad local.

En nuestro contexto, la figura 18 superpone los perfiles ICE de todas las pacientes junto al PDP medio para cada predictor y revela un patrón claro: el modelo responde de forma estable y coherente a los dominios funcionales y sintomáticos clave. En Social y Cognitive functioning las trayectorias descienden casi en paralelo cuando las puntuaciones caen por debajo de 60-70, lo que confirma que un empeoramiento en estos ámbitos eleva el riesgo de calidad de vida «mejorable» en todo el conjunto; del mismo modo, Fatigue, Pain y Arm symptoms muestran pendientes ascendentes homogéneas, reforzando su papel como desencadenantes uniformes de una predicción negativa. Por el contrario, variables de menor peso clínico —Constipation, Diarrhea o Financial difficulties— exhiben líneas prácticamente planas y superpuestas, evidenciando que permutarlas apenas altera la salida del modelo. Estas observaciones demuestran que el Random Forest se apoya en señales robustas y consistentes entre pacientes, al tiempo que señala qué atributos podrían simplificarse sin pérdida apreciable de desempeño.




Figura 18: ICE de cada variable para el modelo Random Forest

5.5 Local Interpretable Model-agnostic Explanations (LIME)

LIME es un método de explicabilidad post-hoc y agnóstico al modelo que genera interpretaciones locales: explica por qué el clasificador produce una predicción concreta en una observación individual. Para ello, crea un pequeño conjunto sintético de muestras en torno al caso de interés mediante perturbaciones aleatorias de sus características. Luego, evalúa el modelo «opaco» sobre ese vecindario y ajusta un predictor lineal o de baja complejidad ponderado por la proximidad de cada muestra al punto original. Los coeficientes de este modelo local ofrecen una aproximación lineal de la superficie de decisión en esa región, indicando la contribución (positiva o negativa) de cada variable a la clase predicha.

Al ser independiente del tipo de algoritmo y centrarse en la región relevante para el paciente, LIME facilita que los expertos de dominio comprendan cuáles son los factores que impulsan la recomendación en cada caso y detecten, si procede, discrepancias con el juicio experto o sesgos inadvertidos, sin necesidad de inspeccionar la lógica global del modelo. Este acercamiento permite obtener conocimiento para desarrollar una medicina personalizada como veremos más adelante.

Para este análisis se han examinado los 4 tipos diferentes de clasificaciones: verdadero positivo, falso negativo, falso positivo y verdadero negativo. Esta selección permite contrastar el razonamiento del modelo en situaciones favorables y en errores, ayudando a identificar posibles patrones y comprender las decisiones más detalladamente.

En la Figura 19 puede verse la explicación generada por LIME para un caso verdadero positivo. Revela que la predicción del modelo está fuertemente respaldada por un perfil clínico negativo. Las características funcionales presentan valores medio-bajos y

contribuyen a la clase «mejorable», mientras los valores altos en fatiga y dolor inclinan la clasificación aún más. Además, Es destacable observar como un nivel relativamente alto de Physical functioning (80) tiene incidencia en la clasificación y como el modelo le atribuye una importancia relativamente alta en este caso.




Figura 19: Explicación LIME de la clasificación del caso verdadero positivo # 180 de Random Forest

En el caso del falso negativo, la Figura 20 muestra como la predicción tiene coherencia clínica, ya que todas las variables sintomáticas tienen valores mínimos, mientras entre los funcionamientos únicamente el físico presenta un valor medio-bajo. La explicación de LIME revela que la predicción se sustenta en valores altos en dimensiones funcionales clave (Social, Emotional y Cognitive), mientras que variables que podrían indicar deterioro, como Fatigue o Arm Symptoms, están en niveles nulos y mínimos respectivamente. Esto sugiere que el modelo prioriza marcadores positivos fuertes y podría estar infraestimado señales clínicas sutiles.

Es importante destacar que un valor alto de Role functioning contribuye a la clasificación como mejorable. Este comportamiento puede parecer paradójico en un primer momento, sin embargo, en el análisis exploratorio hemos visto dos puntos muy interesantes de Physical y Role functioning:

- Un buen funcionamiento físico o de rol no es condición suficiente para una mejor percepción de la calidad de vida.
- Las personas tienen menor tolerancia a un mal funcionamiento físico y de rol para obtener una percepción de calidad de vida alta (requieren valores muy altos).

Es decir, un valor de 83,33 no es lo suficientemente alto para obtener una calidad de vida aceptable y «empuja» el modelo hacia la clase mejorable.

En cuanto a los síntomas, vemos que excepto fatiga y Arm symptoms el resto no tiene una gran incidencia.

Este tipo de error es crítico en contextos clínicos, donde no detectar un caso mejorable implica la pérdida de oportunidad terapéutica, si bien esta observación parece ser un caso extremo en cuanto a lo «paradójico del comportamiento». Este tipo de error refleja una limitación en la sensibilidad del modelo, especialmente ante perfiles clínicamente contradictorios, y resalta la importancia de utilizar explicabilidad para entender qué información está priorizando o descartando en sus decisiones puntuales.



Figura 20: Explicación LIME de la clasificación del caso falso negativo # 271 de Random Forest

En el caso del falso positivo, LIME muestra que se trata de una predicción alta (0.76 mejorable) que se ha visto condicionada por valores altos en Arm symptoms, 33,33 y el punto de discriminación es 23,81, y valores bajos en Physical functioning (80), empujando el modelo hacia la clase positiva. Aunque el resto de variables funcionales y valores óptimos, estas dos dimensiones parecen haber tenido un peso decisivo. Esto muestra que el modelo puede priorizar con fuerza marcadores negativos aislados — especialmente si afectan al estado funcional— aunque el perfil general de la persona sea favorable. Es un ejemplo típico de cómo el modelo actúa con sensibilidad ante dominios concretos y cómo LIME permite interpretar esas decisiones en la frontera.

Por último, la predicción verdadera negativa es un ejemplo claro de decisión correctamente clasificada con un valor crudo alto (0,79). LIME revela que la predicción se apoya principalmente en variables funcionales con valores óptimos, como Social, Physical, Role y Body image, que empujan con fuerza hacia la clase correcta junto con valores nulos en los síntomas más importantes.

En conjunto, LIME valida que el Random Forest utiliza señales coherentes clínicamente y permite aislar los escenarios donde la ponderación de las variables es discutible (casos frontera), para poder encontrar patrones o señales de alerta que permitan derivar estos casos al estudio de un experto.

5.6 Diverse Counterfactual Explanations (DiCE)

Para complementar las explicaciones locales, hemos utilizado DiCE como herramienta para generar contraejemplos: instancias sintéticas mínimamente modificadas que cambiarían la predicción del modelo. El objetivo de esta técnica es identificar qué variables deberían variar —y en qué dirección— para que un caso cambie de clase, proporcionando así una interpretación directa y accionable en casos concretos como instrumento de medicina personalizada.

En el contexto clínico, DiCE permite entender qué mejoras específicas en los atributos de una paciente podrían aumentar la probabilidad de recibir una predicción favorable. Además, revela posibles dependencias implícitas del modelo respecto a ciertas variables o combinaciones. Esta estrategia resulta especialmente útil en el análisis de observaciones clasificadas erróneamente, ya que permite examinar qué ajustes serían necesarios para obtener una predicción correcta, facilitando una reflexión crítica sobre la robustez del modelo y sus implicaciones prácticas.

Para conseguir los contra ejemplos DiCE necesita un dataframe que contenga tanto las características que el modelo utiliza para hacer predicciones como la variable objetivo (QoL). Esto se debe a que DiCE genera los contra ejemplos modificando valores de entrada con el fin de cambiar la predicción del modelo respecto a la variable objetivo, por lo que necesita saber cuál es la salida actual para cada instancia y qué valores de entrada la están determinando.

Para analizar la potencia de esta herramienta, la hemos aplicado a un caso «mejorable» con el objetivo de estudiar como transformarlo en «aceptable». Para el caso particular DiCE ha generado con éxito 5 contraejemplos que modifican la predicción, variando únicamente las variables Fatigue y Cognitive functioning. Los valores reales de la observación para estas variables son:

Fatigue:	33,33
Cognitive Functioning:	77,78

En todos los contraejemplos, el modelo cambia su predicción cuando se reduce significativamente la fatiga y se incrementa el funcionamiento cognitivo, sin necesidad de alterar otras dimensiones clínicas. Esto indica que el modelo responde con sensibilidad a estos dos factores de forma combinada, lo que refuerza su utilidad como herramienta para detectar configuraciones mínimas y clínicamente interpretables que podrían cambiar la decisión del sistema. La tabla 5 muestra las combinaciones para cada uno de los contraejemplos encontrados.

La observación revela que si se anula la fatiga, incluso sin aumentar el funcionamiento cognitivo podría obtenerse un QoL aceptable (caso 5). Este conocimiento puede ser de suma utilidad para la generación de herramientas que den apoyo al personal profesional sanitario.

Tabla 5: Contraejemplos generados por DiCE

Caso	Cognitive functioning	Fatigue
1	88,89	0
2	100	11,12
3	100	22,23
4	66,67	0
5	-	0

Al profundizar en la relación de ambas variables mediante PDP bidireccional, encontramos que con una fatiga de 33,33 y un funcionamiento cognitivo de 77,78, nos encontramos en la zona delimitada por una probabilidad heurística entre 0,50 y 0,54. Pero si nos movemos a valores de fatiga inferiores a ≈ 20 y de funcionamiento cognitivo superiores a 80, la clasificación se encuentra en los límites del umbral de decisión y puede transformarse en aceptable.

La gráfica de dependencia parcial conjunta entre Cognitive functioning y Fatigue refuerza los hallazgos obtenidos con DiCE. En la Figura 21 se observa que la predicción de la clase mejorable disminuye notablemente en las regiones donde el funcionamiento

cognitivo es alto y la fatiga es baja. Esta zona —arriba a la izquierda— coincide con los contraejemplos generados automáticamente, y delimita claramente un espacio de decisión en el que el modelo considera que la calidad de vida es aceptable. La frontera de decisión se curva de forma no lineal, lo que sugiere una interacción entre ambas variables: el efecto positivo de la mejora cognitiva es más fuerte cuando va acompañado de una reducción simultánea de la fatiga. Esto valida el enfoque contrafactual y confirma que el modelo ha aprendido una interacción clínicamente razonable, que puede aplicarse en la toma de decisiones.




Figura 21: PDP de Cognitive functioning y Fatigue

5.7 SHapley Additive exPlanations (SHAP)

SHAP traslada la teoría de juegos cooperativos al terreno de la explicación algorítmica [40]: para cada observación, calcula el valor de Shapley [39] de cada característica, entendido como la contribución «justa» que esa variable añade a la predicción frente a una referencia neutra (*baseline*). El resultado es una descomposición aditiva exacta, ya que la suma de todas las aportaciones individuales —más el valor base— reproduce al céntimo la probabilidad generada por el modelo. Esta propiedad de contabilidad perfecta diferencia a SHAP de la mayoría de métodos locales y permite comparar, con la misma escala, explicaciones puntuales y resultados agregados.

Para entender por qué esta descomposición es única y justa, recordemos —muy brevemente— la definición del valor de Shapley en teoría de juegos y su traslación al aprendizaje automático. En este contexto, los «jugadores» son las variables de entrada y el «juego» consiste en producir la predicción de un modelo f . Tomamos como referencia el valor base

$$\phi_0 = \mathbb{E}[f(X)]$$

es decir, la salida media del modelo sobre todo el conjunto de datos X . Para un subconjunto S de características fijadas en sus valores reales x_S , definimos

$$f(S) = \mathbb{E}[f(X) \mid X_S = x_S] \quad ^5$$

⁵ Descripción basada en la adaptación de Lundberg (2017) [40] de los valores de Shapley [39]

donde las demás variables se promedian considerando todos sus valores posibles en el conjunto de datos. De esta forma, $f(S)$ representa «lo que esperaría el modelo» si conociésemos solo esas variables.

El valor de Shapley ϕ_j mide cuánto contribuye la característica j (en la observación concreta) a desplazar la predicción desde ϕ_0 hasta el valor final. Esta descomposición es única, ya que los valores de Shapley son la única asignación que satisface simultáneamente los axiomas de eficiencia, simetría, jugador nulo y aditividad, garantizando un reparto justo de la predicción entre las variables. Por construcción:

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j \quad 5$$

de modo que la suma de todas las aportaciones reproduce exactamente la salida del modelo, convirtiendo a SHAP en un método de atribución local coherente y aditivo.

Además de su fidelidad matemática, SHAP ofrece dos ventajas clave para el caso de estudio. En primer lugar, los impactos medios de las variables (SHAP global) guardan coherencia con las explicaciones caso a caso, de modo que las variables que más influyen de forma agregada son las mismas que aparecen reiteradamente como impulsoras o atenuantes en los perfiles individuales. En segundo lugar, el signo de cada valor SHAP indica si la característica empuja la predicción hacia la clase «mejorable» (positivo) o «aceptable» (negativo), facilitando la interpretación conjunta de variables de funcionamiento y síntomas.

En conjunto, la descomposición aditiva única de SHAP ofrece una explicación cuantitativa, completa y acorde a la normativa de la UE, facilitando tanto la validación interna del modelo como la rendición de cuentas ante auditores o profesionales clínicos.

La figura 22 (*beeswarm*) muestra, para cada observación del conjunto de prueba, cuánto empuja cada variable la predicción del Random Forest hacia la clase mejorable (valores positivos a la derecha) o hacia aceptable (negativos a la izquierda). El eje vertical ordena los predictores por importancia global, la anchura de la franja indica la magnitud media absoluta del valor SHAP y el color codifica el valor real de la característica: azul para bajo, fucsia para alto. Por lo tanto, la *beeswarm* combina, en una sola imagen, importancia global mediante la posición en el eje Y y variabilidad local con la dispersión en el eje X y el gradiente de color.

Social y Cognitive functioning encabezan la lista: los valores altos en rojo desplazan fuertemente el output hacia la izquierda —mejor pronóstico—, mientras los bajos en azul lo desplazan a la derecha, corroborando su papel protector ya observado en PDP e ICE.

Arm symptoms y Fatigue muestran un efecto umbral, ya que valores bajos —puntos azules a la izquierda del eje— desplazan la predicción hacia «aceptable», pero en cuanto superan la franja baja-media (≈ 30 -50) los SHAP se vuelven positivos —morado-rojo a la derecha—, lo que incrementa de manera apreciable la posibilidad de clasificar el QoL como «mejorable».



Figura 22: Beeswarm de valores SHAP en el conjunto de prueba.

Los funcionamientos social y emocional muestran como sus valores altos influyen en la clasificación como aceptable, mientras el físico y de rol tienen efectos menos acusados y aún valores altos empujan la clasificación como mejorable. Más estrechos pero todavía influyentes: las contribuciones del funcionamiento sexual y la imagen corporal se agrupan en torno a cero.

Por último, síntomas como Diarrea o Constipation concentran la mayor parte de sus puntos cerca de 0, confirmando su irrelevancia ya sugerida por la Permutation Feature Importance.

Al analizar el caso verdadero positivo # 240 con SHAP, en la Figura 23, encontramos que la observación fue clasificada como mejorable con un valor crudo elevado $f(X) = 0.93$, partiendo de una línea base $E[f(X)] = 0.52$. Las variables con mayor impacto positivo en esta predicción son Fatigue, Social functioning y Emotional functioning, seguidas por Pain y cognitive y Role functioning. Las funcionales presentan valores intermedios o bajos que el modelo asocia a deterioro. En sentido contrario, solo Appetite loss ejerce un débil efecto corrector.




Figura 23: Shapley Values para las características del caso verdadero positivo # 180 de RandomForest

La explicación muestra una composición clínica razonable y proporciona interpretabilidad a nivel individual, lo que resulta clave para su aplicación en entornos clínicos como herramienta de medicina personalizada: ¿Qué pasaría si se redujera la fatiga y se aumentara el funcionamiento social o cognitivo en esta paciente, como se ha visto con DiCE?

El caso del falso negativo, los errores críticos que se desean minimizar, al analizar la explicación proporcionada por SHAP encontramos que, partiendo siempre de la misma *baseline*, la predicción del modelo para la clase mejorable fue de 0,32. Los valores Shapley indican un comportamiento del modelo coherente con el conocimiento que hemos acumulado hasta el momento. Es decir, valores sintomáticos bajos — especialmente en fatiga— y funcionales altos empujan al modelo a esperar un QoL «aceptable».

Este caso pone de manifiesto como el modelo puede infravalorar algunas señales de deterioro del QoL cuando el perfil general es óptimo, derivando en pérdida de sensibilidad en determinados contextos clínicos. Sin embargo, su decisión se encuentra fundamentada en un patrón global de buen funcionamiento, por lo que el error no es arbitrario, sino que se produce porque los dominios funcionales que el modelo ha aprendido a priorizar presentan sus valores óptimos.

El modelo opera de manera coherente con la lógica clínica, aunque presenta ciertas limitaciones en los casos cercanos al umbral, una conclusión valiosa para decidir si conviene reajustar el umbral de decisión o incorporar nuevas variables que eleven la señal de alerta en estos casos limítrofes.

6. Cuantificación de la Incertidumbre

En el contexto de los sistemas de inteligencia artificial, la cuantificación de la incertidumbre se refiere al conjunto de técnicas y metodologías que permiten estimar y comunicar cuánta confianza podemos depositar en las predicciones de un modelo. A diferencia de las métricas clásicas de rendimiento (precisión, recall, AUC...), que miden cuán bien se ajusta el modelo a datos etiquetados, la cuantificación de la incertidumbre nos ayuda a identificar cuándo el modelo está operando fuera de su «zona de confort» — por ejemplo en regiones del espacio de entrada poco representadas en el entrenamiento — y, en consecuencia, sus salidas son menos fiables.

Los *scores* que devuelven la mayoría de los clasificadores, por ejemplo las puntuaciones crudas del método `predict_proba` de Scikit-Learn, no corresponden a probabilidades verdaderas, como se ha mencionado en el apartado 4.2 Interpretación de las predicciones. Si quisiéramos interpretar esos *scores* como probabilidades —o extraer de ellos intervalos fiables de incertidumbre—, necesitamos primero alinear esas estimaciones con las frecuencias reales observadas en datos conocidos.

Los principales enfoques de cuantificación de la incertidumbre, en clasificación binaria, se pueden agrupar en tres grandes categorías:

Métodos bayesianos y variacionales

Incorporan distribuciones a priori sobre sus parámetros y, a través de inferencia, devuelven distribuciones a posteriori sobre las predicciones, reflejando así la incertidumbre debida a la falta de datos [41].

Ensamblados y métodos de Monte Carlo Dropout

Construyen múltiples réplicas del predictor —ya sea entrenando varios árboles en un bosque aleatorio, varios modelos en un Boosting, o aplicando dropout a redes neuronales— y utilizan la dispersión entre esas réplicas como una medida de su confianza [42].

Métodos conformes (Conformal Prediction y Venn–Abers)

Proporcionan garantías de validez frecuentista, garantizando que el porcentaje de respuestas verdaderas quede dentro del intervalo de predicción con la probabilidad deseada, sin asumir distribución particular de los datos. Venn–Abers es un método inductivo que extiende el marco de la calibración clásica para producir, para cada instancia de prueba, un intervalo de probabilidad $[p_0, p_1]$ con cobertura garantizada de contener el valor verdadero (*ground truth*) [10][43].

En este trabajo nos centramos en el tercer bloque —los métodos conformes— y, especialmente, en Inductive Venn–Abers Predictors (IVAP) porque es el único capaz de producir intervalos de probabilidad con cobertura frecuentista garantizada [44].

6.1 Calibración clásica: Platt Scaling e Isotonic Regression

Tras entrenar el clasificador base, pueden aplicarse funciones monótonas sobre sus scores para mejorar la concordancia global entre probabilidades y frecuencias empíricas:

Platt Scaling

Ajusta un sigmoide a los scores de un modelo mediante validación cruzada [45].

Isotonic Regression

Aprende una función escalonada no decreciente sobre los scores, minimizando error cuadrático [46].

Sin embargo, ninguno de los dos ofrece garantías de cobertura frecuentista.

6.2 Predicción Conforme

Las Predicciones Conformes (CP) forman un marco agnóstico al modelo que, partiendo de la suposición mínima de intercambiabilidad de los datos —los ejemplos de calibración y prueba se tratan como extraídos sin orden relevante—, asigna a cada nueva instancia un intervalo de predicción o un conjunto de clases garantizando, en un sentido frecuentista, que la fracción verdadera de etiquetas quedará dentro de ese intervalo con la probabilidad deseada.

En el marco genérico de la Predicción Conforme clásica introducimos un nivel de significación α , por ejemplo: $\alpha=0.05$ para garantizar un 95 % de cobertura, junto con la definición de una medida de no-conformidad y el cálculo de p-valores conformes. En cambio, Venn–Abers es un predictor inductivo conformal diseñado específicamente para clasificación binaria que prescinde de todos esos pasos: no requiere ni α , ni non-conformity scores ni p-valores. En su lugar, produce directamente para cada instancia un intervalo de probabilidad delimitado por $[p_0, p_1]$ que cumple la cobertura frecuentista.

Vovk, et al. (2005) [8] desarrollaron el algoritmo completo y Papadopoulos et al. (2002) [47] realizaron una exposición tutorial, con énfasis en la *nonconformity score* y variantes prácticas:

- 1 Medida de no-conformidad: se define una *nonconformity score* que cuantifica cuán inusual es cada ejemplo respecto al modelo, por ejemplo: el complemento de la clase verdadera o bien la hinge loss definida en Cortes & Vapnik (1995) [48].
- 2 Conjunto de calibración: tras entrenar el modelo sobre un primer bloque de datos, se reserva un segundo subconjunto para computar las *nonconformity scores* de ejemplos con etiqueta conocida.

- 3 Cálculo de p-valores conformes: para cada posible etiqueta de la nueva instancia, se calcula qué proporción de scores en el conjunto de calibración sería más inusual —peor— que la puntuación obtenida añadiendo hipotéticamente esa etiqueta. Ese p-valor conformal mide la compatibilidad de la etiqueta con los datos observados.
- 4 Construcción del intervalo o conjunto de predicción: dadas unas tolerancias o nivel de significación, se incluyen en la predicción todas aquellas etiquetas cuyo p-valor exceda el umbral. En clasificación binaria esto deriva en un intervalo de probabilidad o —en su versión Venn-Abers— directamente en un rango $[p_0, p_1]$ para la probabilidad de la clase positiva.
- 5 Garantía de validez: bajo la hipótesis de intercambiabilidad, CP asegura que la cobertura real, es decir la frecuencia con que la verdad yace dentro del conjunto, no sea inferior al nivel nominal fijado, sin asumir ninguna forma paramétrica para la distribución de los datos.

En la práctica existen dos grandes variantes: Transductive CP recalcula el modelo cada vez que llega una nueva instancia, mientras Inductive CP entrena una sola vez y emplea un conjunto de calibración externo, lo que reduce drásticamente la carga computacional.

Los Inductive Venn-Abers Predictors (IVAP) son una forma de CP inductiva que, en lugar de generar conjuntos de clases, producen directamente un intervalo de probabilidades bien calibrado para la clase positiva, combinando la validación frecuentista de CP con técnicas de calibración de scores.

En este trabajo hemos aplicado la implementación explicada en el tutorial de Paolo Toccaceli (2019) [49], utilizando su desarrollo en Python [50], del pseudocódigo del algoritmo definido originalmente por Vovk, Gammerman y Shafer (2005) [8]; cuyos detalles se describen brevemente en el anexo 10.1.

6.3 Calibración del modelo y resultados

Para que la calibración conformal proporcione garantías fiables de cobertura es aconsejable disponer de al menos mil instancias en el conjunto de calibración [10]. En nuestro caso, el volumen total de datos está muy por debajo de ese umbral, lo cual limita la precisión tanto de la calibración como de las métricas resultantes, una situación habitual en pruebas de concepto con Big Data incipiente y escaso, como es el caso de los PROMs que utilizamos en este trabajo. Por ello, aunque nuestras métricas son razonables, su validez en escenarios reales requeriría replicación y validación con conjuntos de datos de mayor tamaño.

Para la cuantificación de la incertidumbre de nuestro clasificador, comenzamos por inspeccionar la distribución de las probabilidades heurísticas sobre el conjunto de prueba. Esto nos permite ver cuántas predicciones caen cerca de 0 o de 1 —zonas de alta confianza— y cuántas se sitúan en la franja intermedia, donde el modelo muestra mayor indecisión. Esa información es clave porque una buena calibración busca alinear esos puntajes con las frecuencias reales de ocurrencia: si el modelo asigna un valor crudo de 0.7 a 100 casos, idealmente deberíamos observar que unos 70 de ellos realmente pertenecen a la clase positiva.

La Figura 24 presenta el histograma de las puntuaciones crudas que arroja el Random Forest sobre el conjunto de prueba. Se aprecia que, si bien existe un pico pronunciado en valores cercanos a 0 y a 1, el resto de las puntuaciones —incluida la franja en torno al umbral de decisión ($\approx 0,423$)— se distribuye de forma más o menos homogénea a lo largo de todo el rango $[0,1]$.




Figura 24: Distribución de las probabilidades heurísticas del Random Forest

Cobertura del modelo

La cobertura de un modelo mide cuán fiable es su nivel de confianza cruda: para un umbral de probabilidad l , definimos la cobertura como la proporción de ejemplos cuya probabilidad predicha $\hat{p}_i$ supera l y que efectivamente pertenecen a la clase positiva. Formalmente:

$$\text{coverage}(l) = P(Y = 1 \mid \hat{p} \geq l) = \frac{\#\{i : \hat{p}_i \geq l \wedge y_i = 1\}}{\#\{i : \hat{p}_i \geq l\}}. \quad [8]$$

Como se ha dicho, si el modelo estuviera perfectamente calibrado esperaríamos que la curva de cobertura siguiese la diagonal $\text{coverage}(l) \approx l$. Cuando la cobertura está por debajo de esa diagonal, el modelo es excesivamente confiado: sus predicciones «seguras» aciertan menos de lo que sugiere la probabilidad cruda. Si, por el contrario, la cobertura está por encima de la diagonal, el modelo es conservador: acierta más de lo indicado. En la práctica, inspeccionar esta curva nos permite elegir los niveles de confianza apropiados para la toma de decisiones.

La curva de cobertura de la figura 25 crece de forma monótonica con el umbral l , arrancando en ≈ 0.53 cuando $l=0$ (que coincide con la prevalencia de la clase positiva en el conjunto de prueba) y alcanzando ≈ 0.9 para l cercano a 1. Sin embargo, a lo largo de todo el rango la cobertura está sistemáticamente por encima de la diagonal. Por ejemplo: con el umbral $l=0.5$ estamos filtrando todas las muestras cuya probabilidad heurística $\hat{p}$ es ≥ 0.5 , su frecuencia real de positivos (cobertura) es de $\approx 80\%$ dentro de ese subconjunto que es mucho mayor que 50% .




Figura 25: Curva de confiabilidad para Random Forest

Curvas de calibración y métricas

Las curvas de calibración, o *reliability diagrams*, son herramientas gráficas que comparan las probabilidades predichas por un modelo con las frecuencias reales de ocurrencia. Para generarlas, se agrupan las predicciones en varios intervalos (*bins*) según su valor medio y se dibuja, para cada *bin*, el par probabilidad media predicha/proporción observada de positivos. Una línea diagonal indica calibración perfecta: desviaciones por encima o por debajo de esa diagonal muestran, respectivamente, un modelo conservador o excesivamente confiado, y guían la necesidad y la elección de métodos de calibración.

El análisis visual se complementa con la introducción de dos métricas numéricas que resumen el grado de alineación entre probabilidades y frecuencias reales: el Brier Score y la Log Loss, que hemos introducido en la selección del modelo y cuantifican de forma complementaria la calidad global y la penalización de errores extremos en las predicciones probabilísticas.

Brier Score

Mide la exactitud global de las probabilidades predichas, calculando la media del cuadrado del error entre la predicción probabilística y la etiqueta verdadera. Un valor bajo indica que las predicciones están cerca de los valores observados, penalizando tanto errores de certeza (predecir 1 cuando es 0) como de falta de confianza (predecir 0 cuando es 1). Es especialmente útil para evaluar la calibración porque trata simétricamente sobre y sub confianza [51].

Log Loss (o entropía cruzada)

Cuantifica la calidad de la distribución de probabilidad completa que ofrece el modelo. Castiga muy fuerte las predicciones extremas equivocadas, y penaliza gradualmente las desviaciones menores de las probabilidades. Al igual que el Brier, cuanto más bajo es, mejor alineación hay entre probabilidades y frecuencias reales, siendo una medida estándar de calidad de calibración en clasificación probabilística [38].

Calibración con Platt Scaling e Isotonic Regression

Al aplicar los métodos clásicos de calibración, observamos que tanto Platt Scaling como Isotonic Regression mejoran la alineación global de las predicciones frente al modelo sin calibrar. En la figura 26, se aprecia como en la zona baja de probabilidades (0.1–0.2), Isotonic y Platt corrigen ligeramente hacia acercándose a la diagonal, mientras que Isotonic suaviza las oscilaciones intermedias (0.25–0.35). En regiones altas (≥ 0.8), ambos métodos ajustan las curvas para acercarse nuevamente más a la diagonal, reduciendo el comportamiento conservador del Random Forest.




Figura 26: Curvas de calibración de Random Forest, RF + Isotonic y RF + Platt

El análisis de la Tabla 6 muestra que las técnicas clásicas de calibración apenas modifican el rendimiento global del Random Forest: la accuracy se mantiene en 0.81, y tanto el Brier Score (0.14) como el Log Loss (0.45) permanecen inalterados. No obstante, Platt Scaling e Isotonic Regression ajustan ligeramente el equilibrio entre recall y precision: en ambos casos la precision sube a 0.84, mientras que el recall baja a 0.79 (Platt) y 0.77 (Isotonic). El F1-score cae marginalmente a 0.81, y la ROC-AUC desciende también muy levemente a 0.87, reflejando una mínima pérdida en la capacidad de discriminación. En conjunto, estas calibraciones clásicas afinan la negociación entre falsos positivos y falsos negativos sin alterar la performance de base del clasificador.

Tabla 6: Métricas obtenidas con Random Forest, RF + Isotonic y RF + Platt

Modelo	Accuracy	F1-score	Recall	Precision	ROC-AUC	Brier Score	LogLoss
Random Forest	0.81	0.82	0.84	0.80	0.88	0.14	0.45
RandomForest + Platt Scaling	0.81	0.81	0.79	0.84	0.87	0.14	0.45
Random Forest + Isotonic Reg.	0.81	0.81	0.77	0.84	0.87	0.14	0.45

Calibración con Venn-Abers

Desde el punto de vista clínico no nos interesa obtener una clasificación mejorable o aceptable cruda, en realidad buscamos una cuantificación de la incertidumbre que aplicada a la clasificación se ajuste lo máximo posible a la realidad. Es decir, para una paciente cuya calidad de vida es mejorable o aceptable, queremos saber en cuanto podemos confiar que la etiqueta se ajuste a la realidad para aceptarla o, por el contrario, investigar más a fondo la clasificación. Además, nos interesa poder dinamizar la elección de este nivel de confianza.

Es en este marco donde la predicción conforme nos brinda las herramientas necesarias para construir intervalos de probabilidad con garantías frecuentistas de cobertura. Como hemos visto, en lugar de entregar un único *score* o etiqueta, Venn-Abers produce para cada paciente un rango tal que, bajo la hipótesis de intercambiabilidad, la proporción real de casos positivos esté contenida en ese intervalo con la confianza deseada. De ese modo podemos elegir dinámicamente, a posteriori, el nivel de confianza —por ejemplo un 90 %— y descartar automáticamente cualquier predicción cuyo intervalo sea demasiado amplio (es decir, con insuficiente certeza) o derivarlo para el análisis de un experto. Este enfoque combina la flexibilidad de la calibración clásica con la solidez estadística de las Predicciones Conformes, adaptándose perfectamente a escenarios clínicos donde el coste de un error es elevado y es crucial cuantificar la incertidumbre de cada diagnóstico.

La Figura 27 recoge, para treinta observaciones tomadas al azar, los intervalos de probabilidad que genera Venn-Abers. Cada muestra aparece representada por dos curvas —una para el límite inferior p_0 y otra para el límite superior p_1 — y el área sombreada entre ambas ilustra la anchura del intervalo. Se aprecia cómo muchas predicciones quedan encapsuladas en bandas muy estrechas, mientras que en algunos intervalos se abren de forma notable, mostrando la indecisión del modelo en esos casos.

Para integrar las predicciones Venn-Abers en sistemas que esperan un único *score*, sin renunciar totalmente a las garantías de validez frecuentista que ofrece el intervalo original, es posible consolidar la predicción «colapsando» dicho intervalo en un único valor. Una forma de conseguirlo, orientada a minimizar la log loss, es la p_{logloss} :

$$p_{\text{logloss}} = \frac{p_1}{1 - p_0 + p_1}$$

que desplaza ligeramente la probabilidad hacia el extremo superior del intervalo como se discute en las extensiones teóricas de Vovk, et al. (2005) [43]. De esta forma, podemos obtener tanto la curva de calibración como las métricas asociadas al modelo calibrado con predicción conforme y realizar las comparaciones con los métodos anteriores.




Figura 27: Intervalo de probabilidad para 30 observaciones al azar

La figura 28 muestra la comparativa del modelo Random Forest sin calibrar (predicciones heurísticas) y las probabilidades (intervalo unificado con p_{logloss}) de Venn-Abers. La curva unificada muestra un comportamiento sensiblemente más suave y monótono que las probabilidades crudas del Random Forest en los primeros bins de baja probabilidad ($\approx 0,1-0,2$). Ambas tienden a subestimar la tasa de positivos, pero Venn-Abers lo hace de forma menos errática. En el rango medio ($\approx 0,2-0,8$) corrige algunas oscilaciones del Random Forest, aunque introduce un exceso de confianza al permanecer por debajo de la diagonal más acusadamente en torno al umbral de decisión (0,423). Finalmente, en el rango superior ($\approx 0,8-1,0$) introduce ligeras oscilaciones locales más acusadas que el Random Forest.




Figura 28: Curva de calibración de RF + Venn-Abers unificado

Al analizar las métricas resultantes de la calibración, en la tabla 7 podemos corroborar que el ajuste mediante IVAP introduce una clara mejoría hacia la detección de positivos: su recall sube a 0.89, mientras que la precision cae de 0.73, lo que provoca una accuracy global menor (0.77 frente a 0.81). Este comportamiento responde a la voluntad de capturar casi todos los casos positivos —objetivo en contextos clínicos— a costa de asumir más falsos positivos. La ROC AUC es prácticamente la misma (0.87).

En cuanto a la calidad probabilística, consolidar el intervalo en el punto óptimo para log loss empeora mínimamente tanto el Brier Score (de 0.14 a 0.15) como la log loss (de 0.45 a 0.46), reflejando un desalineamiento mayor entre las probabilidades agregadas y las frecuencias reales. En definitiva, IVAP ofrece garantías de cobertura frecuentista y maximiza el recall, pero no mejora la calidad de clasificación.

Tabla 7: Comparativa de las métricas de Random Forest sin calibrar y Venn-Abers

Modelo	Accuracy	F1-score	Recall	Precision	ROC-AUC	Brier Score	LogLoss
Random Forest	0.81	0.82	0.84	0.80	0.88	0.14	0.45
Random Forest + IVAP	0.77	0.79	0.86	0.73	0.87	0.15	0.46

Una forma de comprender cómo varía la incertidumbre a lo largo del conjunto de prueba consiste en ordenar los casos por su probabilidad unificada (p_{logloss}) y destacar únicamente aquellos con un ancho de intervalo superior a un valor establecido. De este modo comprendemos directamente dónde el modelo está más «seguro» —bandas muy estrechas— y dónde acumula mayor indecisión —bandas anchas—.

La Figura 29 ilustra esta configuración de filtrado y ordenación. En el eje horizontal se muestran únicamente aquellas muestras cuyo intervalo conforme tiene un ancho mínimo de 0,1, ordenadas según su probabilidad IVAP unificada. En el eje vertical aparecen los distintos valores de probabilidad para cada caso: probabilidad heurística del modelo, límite inferior del intervalo (p_0), límite superior del intervalo (p_1) y la p unificada.




Figura 29: Intervalos de confianza IVAP con ancho mayor o igual a 0,1

Salvo en torno a la parte superior del umbral de decisión, todas las puntuaciones crudas quedan dentro del intervalo de incertidumbre. A la izquierda, donde la probabilidad es baja, los intervalos son estrechos. A medida que avanzamos hacia valores medios, los intervalos se abren ligeramente reflejando mayor indecisión del modelo. Finalmente, en la

zona de altas probabilidades ($>0,8$) vuelven a estrecharse mostrando mayor confianza. Esta gráfica muestra como los resultados que arroja Random Forest para estas observaciones se encuentran relativamente calibradas. La cuantificación nos permite identificar de forma directa las observaciones más inciertas y las más confiables de acuerdo al ancho del intervalo (línea continua verde). De esta forma, podemos determinar un ancho máximo por debajo del cual aceptamos automáticamente las predicciones, y derivamos al experto clínico aquellas instancias cuyo nivel de certeza no cumple el requisito.

6.4 Explicabilidad de predicciones no confiables

Una vez determinados los intervalos de confianza, analizamos más de cerca un caso destacado donde el modelo predice con inseguridad (intervalo amplio) y la probabilidad de una calidad de vida aceptable es elevada. En especial, nos interesan los casos críticos, donde potencialmente se pierde capacidad de intervención, correspondientes a los falsos negativos.

Para ilustrar cómo SHAP nos ayuda a desentrañar las razones detrás de esa alta incertidumbre, tomamos el falso negativo con el mayor ancho de intervalo y le aplicamos un análisis local. Con un TreeExplainer sobre nuestro Random Forest ya entrenado, calculamos los valores SHAP para esa instancia y visualizamos su descomposición en un diagrama tipo «waterfall». Como hemos visto en el capítulo de explicabilidad, este gráfico nos muestra de forma acumulativa qué variables empujan la predicción hacia arriba o hacia abajo respecto al valor base. Es decir, buscamos revelar las características que contribuyeron en mayor medida tanto al puntaje crudo como al amplio intervalo conformal que refleja la inseguridad del modelo en este caso crítico.

La observación seleccionada corresponde al máximo de intervalo en el conjunto, para un falso negativo, con los siguientes valores:

Puntaje crudo	p_logloss	p0	p1	Ancho de Intervalo	Punto Medio	QoL	Predicción IVAP	Predicción Modelo
0.27	0.29	0.18	0.33	0.15	0.26	mejorable	aceptable	aceptable

La explicación de SHAP de la figura 30 indica cómo valores altos de funcionamiento social, junto con valores bajos de fatiga y Arm symptoms empujan la predicción hacia una mayor probabilidad de «aceptable». Como hemos visto, el modelo tiende a sobrevalorar los aspectos funcionales en algunos casos límite. Esto puede explicar por qué Venn–Abers genera un intervalo tan amplio: la indecisión no proviene de un único rasgo, sino de una tendencia en este tipo de casos que disminuyen la confianza del clasificador al no valorar correctamente las señales sintomáticas: por ejemplo, la fatiga y la pérdida de apetito en este caso.




Figura 30: Explicación de SHAP para una observación FN con intervalo de confianza de máxima amplitud

6.5 Conclusiones de la calibración

En resumen, el análisis confirma que las probabilidades crudas de un Random Forest no pueden interpretarse directamente como «certezas» sin calibración, ya que las probabilidades heurísticas y su relación con las frecuencias reales de acierto revela un sesgo conservador que, sin garantías, dificulta la gestión del riesgo clínico. Las técnicas clásicas de calibración como Platt Scaling e Isotonic Regression no mejoran significativamente la concordancia entre predicción y realidad —reflejado en curvas de calibración y valores de Brier Score y Log Loss muy similares al modelo sin calibrar—, además carecen de avales probabilísticos.

En este contexto, Venn-Abers aporta el valor diferencial de generar un intervalo de probabilidad con cobertura frecuentista garantizada. Estos rangos facilitan la selección dinámica de un valor de amplitud ε , que puede ser asociado al grado de incertidumbre, para la identificación automática de casos inciertos que requieren revisión experta. Sin embargo tampoco mejora la calibración de forma considerable

En conclusión, podemos afirmar que ninguna de las técnicas aplicadas: Platt Scaling, Isotonic Regression y Venn-Abers han conseguido mejorar la calibración del modelo Random Forest. Este hecho puede deberse bien a que el modelo ha generado resultados

bastante calibrados, o a que las 236 observaciones del conjunto de calibración se encuentran muy por debajo de las 1000 recomendadas por Angelopoulos y Bates [10].

7. Conclusiones

7.1 Desarrollo

Se ha diseñado un flujo de trabajo integral orientado a respaldar la toma de decisiones clínicas y, con ello, mejorar la calidad de vida (QoL) de las personas en tratamiento de cáncer de mama. El proceso parte de la ingesta y depuración de los PROMs EORTC QLQ-C30 y QLQ-C23 [2], continúa con la partición estratificada en conjuntos de entrenamiento, calibración y prueba, la construcción de modelos supervisados basados en árboles de decisión: DecisionTree, RandomForest [27], XGBoost, CatBoost y LightGBM; y culmina con la aplicación de técnicas de explicabilidad [7] y calibración [10] al modelo óptimo.

El análisis exploratorio⁶ reveló dos grandes grupos de predictores con peso clínico claro. Por un lado los dominios funcionales, como el social, cognitivo, físico o emocional mostraron correlaciones positivas con una calidad de vida buena: a mayor puntuación en estos apartados, mejor índice QoL. Por otro lado, en el bloque sintomático, como la fatiga, el insomnio, la disnea o el dolor; todos ellos se asociaron positivamente con la posibilidad de que la calidad de vida sea mala.

En una primera iteración se abordó la clasificación multiclase⁷ (QoL baja, media y alta); sin embargo, ninguno de los modelos separó adecuadamente las clases adyacentes — sobre todo baja frente a media— y el mejor F1-macro apenas alcanzó 0,64. Ante esta limitación, el problema se reformuló como clasificación binaria⁸ (QoL mejorable vs. aceptable).

La reformulación mejoró la discriminación, permitió optimizar el umbral de decisión y simplificó la interpretación clínica. Aunque no se alcanzaron resultados «óptimos», las métricas fueron aceptables, con un rendimiento muy similar entre todos los modelos. Este hecho sugiere que el rendimiento está condicionado principalmente por el reducido tamaño y la naturaleza del conjunto de datos más que por el algoritmo específico utilizado.

Una vez entrenados, los modelos se sometieron a un análisis comparativo de las métricas obtenidas, el grado de calibración y la complejidad computacional para seleccionar el algoritmo con mejores prestaciones, resultando ser Random Forest el que obtuvo un mejor compromiso entre todos los factores. En la figura 31 se pueden observar los valores de F1-macro para cada uno de los 8 experimentos realizados y las técnicas de XAI y UQ que se aplicaron al modelo seleccionado en el flujo de trabajo.

⁶ [https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase 2/1_EDA.ipynb](https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase%202/1_EDA.ipynb)

⁷ [https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase 2/2.1_Modelado_multiclase.ipynb](https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase%202/2.1_Modelado_multiclase.ipynb)

⁸ [https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase 2/2.2_Modelado_binario.ipynb](https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase%202/2.2_Modelado_binario.ipynb)

Sobre el clasificador seleccionado se aplicaron las técnicas de explicabilidad⁹, organizadas en dos niveles complementarios:

- Global, mediante Permutation Feature Importance, Partial Dependence/ICE y SHAP summary, para identificar los dominios funcionales (por ejemplo el Social, el emocional y el cognitivo) y los síntomas (del brazo y la fatiga) que gobiernan la predicción del índice QoL.
- Local, con SHAP waterfall, LIME y DiCE, que permiten inspeccionar casos individuales —incluyendo aquellos con alta incertidumbre— y generar contraejemplos que ilustren intervenciones clínicas potenciales.

La fase de explicabilidad puso de manifiesto patrones coherentes clínicamente en el comportamiento del modelo. Las variables de funcionamiento social, cognitivo y emocional se revelaron como las más importantes para RandomForest a la hora de realizar la clasificación, mientras los síntomas del brazo y la fatiga demostraron mayor incidencia entre las sintomáticas.

Las herramientas de explicabilidad locales, aportaron un conocimiento particularmente valioso para comprender clínicamente la incidencia de los predictores en la clasificación de casos concretos. Mediante DiCE se generaron contra ejemplos plausibles que mostraron qué modificaciones específicas en los índices revertirían un diagnóstico. Por ejemplo, bastó reducir la fatiga y mejorar ligeramente el funcionamiento cognitivo para que una paciente pasara de un nivel mejorable a aceptable. Además, esta relación entre ambas variables pudo corroborarse con los Partial Dependence Plots, que permiten analizar la forma que interacciona un par de predictores en relación a la clasificación que realiza el modelo. La potencia de estas herramientas en conjunto demuestra que el flujo de trabajo puede ser utilizado para dar apoyo al personal sanitario en medicina personalizada.

Para cuantificar la incertidumbre¹⁰ de cada predicción —tal como exige el Reglamento Europeo de IA [5]— se emplearon tanto calibración clásica (Platt Scaling, Isotonic Regression) como Predicción Conforme con Venn–Abers (IVAP). Esta última es la única que proporciona intervalos de probabilidad con cobertura frecuentista garantizada, cruciales para que el personal médico valore la fiabilidad de cada recomendación. Las mejoras aportadas por estas técnicas han sido muy limitadas. En líneas generales, el Random Forest seleccionado presentó resultados muy similares sin calibrar y con la aplicación de las tres técnicas de calibración. Este hecho puede deberse, en gran medida, a la escasa cantidad de observaciones disponibles en el conjunto de calibración.

Finalmente, las técnicas de explicabilidad se aplicaron a las predicciones con mayor incertidumbre, lo que permitió esclarecer por qué el modelo vacila en casos clínicamente limítrofes. En una paciente que el clasificador marcó como aceptable cuando en realidad su QoL era mejorable (falso negativo), el análisis SHAP reveló un patrón clínicamente coherente: puntuaciones funcionales elevadas (social, emocional y cognitiva) y síntomas relativamente leves (fatiga y síntomas del brazo) empujaban la predicción hacia la clase «aceptable», pero la amplitud del intervalo Venn–Abers alertaba de la baja confianza.

⁹ [https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase 2/3_Explicabilidad.ipynb](https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase%202/3_Explicabilidad.ipynb)

¹⁰ [https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase 3/4_Incertidumbre.ipynb](https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial/blob/master/Fase%203/4_Incertidumbre.ipynb)

Este episodio ejemplifica cómo la escasez de datos de entrenamiento dificulta que el modelo interiorice combinaciones atípicas de funciones altas y síntomas moderados, generando amplios rangos de incertidumbre y errores de clasificación. El principal valor aportado es que la conjunción de explicabilidad + cuantificación de la incertidumbre no solo detecta fallos, sino que ofrece evidencias certeras donde es imprescindible la actuación experta humana, tal como reflejan las recomendaciones de la Unión Europea.




Figura 31: Métricas obtenidas para todos los modelos entrenados y técnicas de XAI y UQ aplicadas al modelo seleccionado

7.2 Alcance del objetivo

El proyecto ha demostrado que es posible predecir el índice de calidad de vida (QoL) en pacientes con tratamiento oncológico, a partir de los índices calculados de los PROMs EORTC QLQ-C30 y EORTC QLQ-C23, mediante aprendizaje automático supervisado y satisfaciendo los requisitos de IA fiable. Las técnicas de explicabilidad aplicadas han mostrado una gran capacidad de generar conocimiento, no solo acerca del comportamiento del modelo sino también del dominio, mientras la cuantificación de la incertidumbre con Predicción Conforme se ha visto limitada por la baja cantidad de observaciones disponibles para la calibración.

Es importante subrayar que las observaciones analizadas proceden de personas reales atendidas en la práctica clínica, no de simulaciones ni repositorios sintéticos. Este hecho confiere al estudio un valor añadido frente a muchas pruebas de concepto en IA sanitaria: las distribuciones, la variabilidad de respuestas y la presencia inevitable de correlaciones complejas reflejan con fidelidad la dificultad del entorno hospitalario.

Trabajar con datos auténticos fortalece la validez de los modelos y permite extraer lecciones operativas que pueden trasladarse de inmediato a la consulta, por ejemplo: cómo afectan los síntomas más prevalentes a la calidad de vida. Al mismo tiempo, expone las limitaciones inherentes a los sistemas de información clínicos, como tamaño

muestral ajustado, clases desequilibradas y ausencia de variables relevantes que podrían enriquecer la información, por ejemplo el tipo de tratamiento.

En cuanto al objetivo principal del trabajo, podemos afirmar que pese al tamaño muestral limitado (lo que penaliza la clasificación y la calibración), los resultados muestran que es factible anticipar la probabilidad de una calidad de vida «aceptable» o «mejorable» con métricas competitivas, explicar los dominios funcionales y sintomáticos que más influyen en ese pronóstico y, además, acompañar cada predicción de un intervalo de confianza interpretable por las y los profesionales sanitarios. Todo ello sienta las bases para desplegar un sistema de apoyo a la decisión que cumpla con las recomendaciones de la Unión Europea, priorice a las y los pacientes con mayor riesgo de deterioro, optimice el seguimiento para una medicina personalizada y, fundamentalmente, mejore el bienestar de las personas que es el objetivo del trabajo realizado.

7.3 Limitaciones

Tamaño y representatividad del conjunto de datos

El estudio se apoya en 1.474 observaciones, un volumen muy por debajo del umbral (≈ 10000 ejemplos) que la literatura [13] recomienda para la clasificación de datos tabulares con árboles de decisión. Esta escasez empeora en la partición triple: entrenamiento, prueba y calibración; donde este último subconjunto incluye apenas 236 casos considerados insuficientes para obtener resultados óptimos [10]. Además, el conjunto de prueba apenas permite evaluar con solidez la generalización; y las 943 instancias de entrenamiento pueden no bastar para capturar la complejidad clínica del dominio.

Las limitaciones de volumen explican tanto la amplitud de algunos intervalos de incertidumbre como la falta de mejoras más acusadas en las métricas globales. Además, la cantidad de errores de ambos tipos (sobre todo los falsos positivos) ha demostrado que los modelos no son del todo capaces en encontrar los patrones subyacentes del dominio. Este hecho produce que varios predictores clínicamente relevantes aparecen con importancias bajas: no porque carezcan de efecto, sino porque la muestra disponible no permite detectarlo de forma estadísticamente robusta.

Acciones no realizadas

Incorporar las variables sociodemográficas disponibles:

Variables como edad, nivel educativo, situación laboral, etc. Podrían aportar matices valiosos al perfil de cada paciente. No obstante, este acercamiento presenta no pocos desafíos. En primer lugar, se corre el riesgo de incurrir en la maldición de la dimensionalidad [54], con 1.474 casos y ya 20 predictores clínicos, añadir nuevos atributos hubiese elevado la dimensionalidad sin un aumento proporcional del tamaño muestral, incrementando el riesgo de sobreajuste y de inestabilidad estadística. En segundo lugar, variables ligadas a género, etnia o estatus socioeconómico pueden reflejar desigualdades estructurales, que si se integran sin un control riguroso se puede trasladar esas injusticias al modelo [15]. Su uso exigiría análisis de equidad, técnicas de mitigación de sesgos y supervisión continua para garantizar un impacto ético aceptable,

que por cuestiones de tiempo y conocimientos no ha sido posible aplicar. Por último, sería necesario seleccionar detenidamente aquellos atributos que no comprometan la capacidad de generalización internacional obtenida con la estandarización de los PROMs utilizados. Este factor requiere un estudio conjunto con personas expertas en la materia y unos recursos de los cuales no se dispone. Sin embargo, esta ampliación no se debe descartar definitivamente y podría ser abordada en un futuro.

Utilización de variables con datos faltantes:

La utilización de modelos como CatBoost y LightGBM permite incorporar variables con datos faltantes gracias a su soporte nativo. El primero detecta los NaN y asigna una «rama de valor faltante» durante la construcción de los árboles. El segundo considera el valor ausente como una posible dirección de división y aprende automáticamente dónde situarlo para minimizar la pérdida. Sin embargo, es aconsejable analizar la naturaleza de los huecos y documentar cómo influye esa «información de la ausencia» en las predicciones. Este factor, añade un grado más de complejidad al flujo de trabajo que no se ha visto justificado por la escasa cantidad de observaciones y las limitaciones de tiempo, pero que podría ser tenido en cuenta en un futuro con conjuntos de datos más extensos.

Optimización de hiperparámetros y selección de variables:

Dada la paridad encontrada entre todos los modelos aplicados, habría sido conveniente estudiar una optimización de los hiperparámetros más ajustada. Esta tarea no ha podido llevarse a cabo de manera minuciosa dadas las limitaciones de tiempo. Además, como se ha visto en la explicabilidad del modelo, algunos predictores podrían estar produciendo ruido en la clasificación y habría sido interesante poder evaluar el rendimiento de los modelos reduciendo estas dimensiones.

7.4 Trabajo futuro

El camino marcado con la utilización de datos reales es prometedor, pero los resultados alcanzados, aun siendo satisfactorios como prueba de concepto, distan de ofrecer la solidez necesaria para un despliegue clínico real. La complejidad intrínseca del dominio exige ampliar el volumen y la diversidad del dataset, incorporando no solo más pacientes, sino también registros procedentes de hospitales públicos y privados de distintas regiones y niveles asistenciales. Esta estrategia multicéntrica aportará heterogeneidad demográfica, variabilidad de respuestas y diferencias en la calidad de los datos.

Las herramientas de explicabilidad aplicadas no abarcan todo el espectro existente. Sería interesante explorar y analizar otras tecnologías para incorporar nuevas técnicas que complementen las utilizadas. Por ejemplo, resulta interesante analizar las Calibrated Explanations [52], como método de explicación local de la importancia de las variables y basado en Venn-Abers, porque incorpora explicabilidad y cuantificación de la incertidumbre en conjunto. Además, existen otras técnicas como las causales y de estimación de Efectos Individuales de Tratamiento (ITE) que son muy apropiadas para medicina personalizada y también sería muy conveniente analizar su utilidad [53], entre otras.

Para una aplicación real en el ámbito clínico como herramienta de apoyo decisional, es necesario enmarcar el flujo de trabajo propuesto en un conjunto de sistemas de información. Permitir al personal médico experto analizar y explotar el conocimiento producido de forma transparente, mediante una interfaz apropiada, es imprescindible para garantizar la adopción y el impacto real de la solución. En el anexo 10.3 se propone un diseño preliminar de alto nivel, para este SI.

Finalmente, el flujo de trabajo propuesto ha sido pensado para no depender exclusivamente del dominio utilizado. Es decir, no se encuentra fuertemente acoplado al tratamiento oncológico del cáncer de mama. Su extensibilidad puede ser probada en otros casos clínicos donde la calidad de vida de las personas bajo tratamiento sea un factor de actuación terapéutica: por ejemplo, pacientes con insuficiencia renal sometidos a diálisis o tratamientos pediátricos de larga duración, por citar algunos ejemplos. En todos los casos, será necesario contar con la cantidad y la calidad suficiente de datos para entrenar los modelos.

8. Glosario

Cobertura frecuentista: propiedad de un método de inferencia o predicción que garantiza que, en repetidos experimentos o muestras independientes, la proporción de veces que el intervalo o la probabilidad estimada contiene el valor verdadero tiende al nivel nominal especificado.

Cuantificación de la incertidumbre: conjunto de técnicas y metodologías que estiman y comunican cuánta confianza puede tenerse en las predicciones de un modelo de aprendizaje automático. Incluye procesos de calibración de probabilidades. Por ejemplo: Venn–Abers que genera probabilidades o intervalos con garantías estadísticamente sólidas, de modo que se conozca explícitamente el grado de fiabilidad de cada salida.

Dependiente del modelo (model-specific): técnicas de interpretación o evaluación que aprovechan la estructura interna y los parámetros de un modelo específico. Requieren acceso al funcionamiento interno (algoritmo, pesos, nodos, etc.).

Explicabilidad: conjunto de técnicas que aplicadas a un sistema de inteligencia artificial ofrecen explicaciones claras y comprensibles sobre su funcionamiento interno o sus decisiones, de manera que un usuario pueda comprender por qué el modelo produce un determinado resultado, ya sea a nivel global (cómo opera en su conjunto) o a nivel local (por qué una predicción concreta).

E-waste: véase *green computing*.

Green Computing (Computación Ecológica): conjunto de prácticas, técnicas y tecnologías orientadas a diseñar, fabricar, utilizar y desechar sistemas informáticos con el objetivo de minimizar el consumo de energía, reducir la generación de residuos electrónicos (*e-waste*) y mitigar el impacto ambiental a lo largo de todo su ciclo de vida. Se centra en la eficiencia energética, el uso de materiales sostenibles y la optimización de recursos para promover la sostenibilidad en la infraestructura tecnológica.

Independiente del modelo (model-agnostic): técnicas y herramientas de interpretación o evaluación que pueden aplicarse a cualquier modelo de aprendizaje automático, sin basarse en la estructura interna ni los algoritmos específicos del mismo.

Interpretabilidad: capacidad de un modelo de aprendizaje automático para describir de forma transparente cómo sus características de entrada (variables) contribuyen a cada predicción, de modo que un observador humano pueda entender y justificar la lógica subyacente al resultado.

Modelos transparentes (glass-box): modelos de aprendizaje automático cuya lógica interna y criterios de toma de decisiones son completamente accesibles y comprensibles para el usuario. Permiten rastrear cómo cada característica contribuye a la predicción final.

Modelo opaco (black-box): modelo de aprendizaje automático cuya lógica interna y criterios de decisión no son fácilmente accesibles ni comprensibles por el usuario. Es decir, no permite saber con claridad cómo influyen las características de entrada en el resultado final.

PROMS (Patient-Reported Outcome Measures): instrumentos estandarizados (cuestionarios, encuestas o escalas) que recogen directamente la percepción del paciente sobre su estado de salud, calidad de vida y efectos del tratamiento, sin la interpretación de profesionales sanitarios. Estos datos reflejan aspectos como síntomas, funcionalidad física, bienestar emocional y satisfacción con la atención, y se utilizan para evaluar de forma objetiva el impacto de las intervenciones médicas desde la perspectiva del propio paciente.

Puntuación de no conformidad (nonconformity score): medida cuantitativa de cuánto difiere una instancia nueva respecto a un conjunto de entrenamiento bajo un modelo dado. Se calcula asignando un valor a cada ejemplo que refleja lo atípico que es en comparación con los datos conocidos. En predicción conformal, se utiliza para ordenar ejemplos desde los más conformes (baja puntuación) hasta los menos conformes (alta puntuación) y construir regiones de predicción con cobertura frecuentista.

UQ: véase cuantificación de la incertidumbre.

XAI: véase explicabilidad.

9. Bibliografía

- [1] A. C. Zoni Matta et al., “Encuesta Internacional de Indicadores de Salud Referidos por los Pacientes: el protocolo del Estudio PaRIS en España,” *Revista Española de Salud Pública*, 7 Sept. 2023. [Online]. Available: https://www.sanidad.gob.es/estadEstudios/estadisticas/PaRIS/docs/Protocolo_proyecto_PaRIS_Espana.pdf [Accessed: 25 Feb. 2025].
- [2] European Organisation for Research and Treatment of Cancer (EORTC), “Quality of Life Questionnaires,” EORTC. [Online]. Available: <https://qol.eortc.org/questionnaires/> [Accessed: 26 Feb. 2025].
- [3] Y. H. Liu, J. Jin, and Y. J. Liu, “Machine learning-based random forest for predicting decreased quality of life in thyroid cancer patients after thyroidectomy,” *Supportive Care in Cancer*, vol. 30, no. 3, pp. 2507–2513, 2022, doi: 10.1007/s00520-021-06657-0.
- [4] P. Fayers and A. Bottomley, “Quality of life research within the EORTC – The EORTC QLQ-C30,” *European Journal of Cancer*, vol. 38, suppl., pp. S125–S133, 2002, doi:10.1016/S0959-8049(01)00448-8.
- [5] EU Artificial Intelligence Act, “The AI Act Explorer,” [Online]. Available: <https://artificialintelligenceact.eu/ai-act-explorer/> [Accessed: 27 Feb. 2025].
- [6] Grupo Independiente de Expertos de Alto Nivel sobre Inteligencia Artificial, “Directrices éticas para una IA fiable,” Comisión Europea, Apr. 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai> [Accessed: 27 Feb. 2025].
- [7] C. Molnar, *Interpretable Machine Learning*, 2022. [Online]. Available: <https://christophm.github.io/interpretable-ml-book> [Accessed: 27 Feb. 2025].

- [8] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*. Cambridge, U.K.: Cambridge University Press, 2005. ISBN: 0-521-83465-8.
- [9] P. Gebert, “Quality of Life (QoL) Dataset in Breast Cancer Patients Based on EORTC QLQ-C30,” Mendeley Data, v. 4, 2023. [Online]. Available: <https://data.mendeley.com/datasets/wrhr5862cb/4> [Accessed: 28 Feb. 2025].
- [10] A. N. Angelopoulos and S. Bates, “Conformal Prediction: A Gentle Introduction,” *Foundations and Trends® in Machine Learning*, vol. 16, no. 4, pp. 494–591, 2023, doi:10.1561/2200000101.
- [11] IBM Corporation, “CRISP-DM: A Standard Methodology for Data Mining,” [Online]. Available: https://www.ibm.com/docs/es/SS3RA7_18.4.0/pdf/ModelerCRISPDm.pdf [Accessed: 10 Mar. 2025].
- [12] R. Schwartz-Ziv and A. Armon, “Tabular Data: Deep Learning is Not All You Need,” arXiv preprint arXiv:2106.03253, Nov. 2021. [Online]. Available: <https://doi.org/10.48550/arXiv.2106.03253> [Accessed: 26 Feb. 2025].
- [13] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” in *NeurIPS 2022 Datasets and Benchmarks*, Sept. 2022. [Online]. Available: https://openreview.net/forum?id=Fp7__phQszn [Accessed: 26 Feb. 2025].
- [14] R. Wirth and J. Hipp, “CRISP-DM: Towards a standard process model for data mining,” in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining (PAKDD)*, 2000, pp. 29–39.
- [15] B. Friedman and H. Nissenbaum, “Bias in Computer Systems,” *ACM Transactions on Information Systems*, vol. 14, no. 3, pp. 330–347, Jul. 1996.
- [16] J. Kaplan, “Life-Cycle Energy Consumption of Servers: Implications for Data Centre Sustainability,” *J. Sustain. Comput.*, vol. 5, no. 4, pp. 112–120, 2013.
- [17] A. Beloglazov and R. Buyya, “Optimal Online Deterministic Algorithms and Adaptive Heuristics for Energy and Performance Efficient Dynamic Consolidation of Virtual Machines in Cloud Data Centers,” *Concurrency and Computation: Practice and Experience*, vol. 24, no. 13, pp. 1397–1420, 2012.
- [18] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA: Addison-Wesley, 1977, ISBN: 978-0-387-31742-7. doi:10.1007/978-0-387-32833-1_136.
- [19] EORTC Quality of Life Group, “EORTC QLQ-C30 (version 3),” 1995. [Online]. Available: <https://www.eortc.org/app/uploads/sites/2/2018/08/Specimen-QLQ-C30-English.pdf> [Accessed: 4 Jun. 2025].
- [20] C. Johnson, F. Brunner, and J. M. Blazeby, “EORTC QLQ-C23: Development and validation of the breast cancer module,” *Quality of Life Research*, vol. 29, no. 7, pp. 1875–1884, 2020.

- [21] European Organisation for Research and Treatment of Cancer (EORTC), “Scoring Manual,” EORTC. [Online]. Available: <https://qol.eortc.org/manual/scoring-manual/> [Accessed: 01 May 2025].
- [22] D. B. Rubin, “Inference and missing data,” *Biometrika*, vol. 63, no. 3, pp. 581–592, 1976, doi:10.2307/2335739.
- [23] M. Le Morvan and G. Varoquaux, “Imputation for Prediction: Beware of Diminishing Returns,” in *ICLR 2025 – International Conference on Learning Representations*, 2025. [Online]. Available: <https://openreview.net/forum?id=D1Y2XFgsPI> [Accessed: 2 May 2025].
- [24] T. M. Mitchell, *Machine Learning*. New York, NY: McGraw-Hill, 1997, ISBN: 978-0070428072.
- [25] R. Rifkin and A. Klautau, “In defense of one-vs-all classification,” *Journal of Machine Learning Research*, vol. 5, pp. 101–141, 2004.
- [26] L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone, *Classification and Regression Trees*. Belmont, CA: Wadsworth, 1984.
- [27] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [28] L. Breiman, “Bagging predictors,” *Machine Learning*, vol. 24, no. 2, pp. 123–140, 1996.
- [29] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [30] J. H. Friedman, “Greedy function approximation: a gradient boosting machine,” *Ann. Statist.*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [31] Scikit-learn developers, “Glossary — predict_proba,” *scikit-learn documentation*. [Online]. Available: https://scikit-learn.org/stable/glossary.html#term-predict_proba [Accessed: 9 May 2025].
- [32] Scikit-learn developers, “_forest.py,” *scikit-learn*, GitHub repository. [Online]. Available: https://github.com/scikit-learn/scikit-learn/blob/main/sklearn/ensemble/_forest.py [Accessed: 9 May 2025].
- [33] B. Zadrozny and C. Elkan, “Transforming classifier scores into accurate multilabel probability estimates,” in *Proc. 8th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2002, pp. 694–699.
- [34] D. M. W. Powers, “Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [35] R. O. Duda, P. E. Hart, and D. G. Stork, *Pattern Classification*, 2nd ed. New York, NY: Wiley, 2001, ch. 2.

- [36] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, 2006.
- [37] European Organisation for Research and Treatment of Cancer – Quality of Life Group, "Guidelines for developing questionnaire," EORTC, Feb. 2018. [Online]. Available: https://www.eortc.org/app/uploads/sites/2/2018/02/guidelines_for_developing_questionnaire_final.pdf [Accessed: 10 May 2025].
- [38] T. Hastie, R. Tibshirani, and J. H. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY: Springer, 2009.
- [39] L. S. Shapley, "A value for n -person games," in *Contributions to the Theory of Games II*, H. W. Kuhn and A. W. Tucker, Eds. Princeton, NJ: Princeton University Press, 1953, pp. 307–317.
- [40] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Proc. 31st Conf. Neural Information Processing Systems (NeurIPS)*, 2017, pp. 4765–4774.
- [41] Y. Gal and Z. Ghahramani, "Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning," in *Proc. 33rd Int. Conf. Machine Learning (ICML)*, 2016, pp. 1050–1059.
- [42] B. Lakshminarayanan, A. Pritzel, and C. Blundell, "Simple and scalable predictive uncertainty estimation using deep ensembles," in *Advances in Neural Information Processing Systems*, 2017, pp. 6405–6416.
- [43] V. Vovk, I. Petej, and O. Fedorova, "Venn–Abers Predictors: A Practical Method for Producing Valid and Well-Calibrated Probability Estimates," *Journal of Machine Learning Research*, vol. 22, no. 205, pp. 1–28, 2021.
- [44] M. Fontana, G. Zeni, and S. Vantini, "Conformal prediction: A unified review of theory and new challenges," *Bernoulli*, vol. 29, no. 1, pp. 1–23, Feb. 2023, doi:10.3150/21-BEJ1447.
- [45] J. C. Platt, "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods," in *Proc. 12th Int. Conf. Neural Information Processing Systems (NIPS)*, 1999, pp. 61–67.
- [46] B. Zadrozny and C. Elkan, "Transforming classifier scores into accurate multilabel probability estimates," in *Proc. 8th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2002, pp. 694–699.
- [47] H. Papadopoulos, A. Proedrou, V. Vovk, and A. Gammerman, "Inductive Confidence Machine," in *Proc. 13th European Conf. on Machine Learning (ECML 2002)*, T. Fawcett and N. Lafferty, Eds., *Lecture Notes in Computer Science*, vol. 2430, Springer, 2002, pp. 345–356, doi:10.1007/3-540-45715-0_43.
- [48] C. Cortes and V. Vapnik, "Support-Vector Networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.

- [49] P. Toccaceli, “Venn–Abers Predictors: A Tutorial,” Centre for Machine Learning, Royal Holloway, University of London, 2020. [Online]. Available: https://cml.rhul.ac.uk/people/ptocca/HomePage/Toccaceli_CP___Venn_Tutorial.pdf [Accessed: 04 Jun. 2025].
- [50] P. Toccaceli, “Venn–Abers Predictors (Python implementation),” GitHub Repository, 2020. [Online]. Available: <https://github.com/ptocca/VennAbers> [Accessed: 04 Jun. 2025].
- [51] G. W. Brier, “Verification of Forecasts Expressed in Terms of Probability,” Monthly Weather Review, vol. 78, no. 1, pp. 1–3, Jan. 1950.
- [52] H. Löfström and T. Löfström, “Calibrated-explanations v0.5.1,” calibrated_explanations documentation. [Online]. Available: <https://calibrated-explanations.readthedocs.io/en/latest/> [Accessed: 04 Jun. 2025].
- [53] M. Janzing y en, “Feature Relevance Quantification in Explainable AI: A Causal Problem,” in Proc. 37th Conf. Neural Information Processing Systems (NeurIPS), 2023.
- [54] R. E. Bellman, Dynamic Programming. Princeton, NJ: Princeton University Press, 1957. ISBN: 978-0691079516.

10 Anexos

10.1 Descripción del algoritmo IVAP utilizado [9]

Paolo Toccaceli (2019)[32][33]

- 1 Se dividen los datos etiquetados en un conjunto de entrenamiento para ajustar el modelo base, y un conjunto de calibración para calcular las nonconformity scores. Del conjunto de calibración, se recogen los pares (s_i, y_i) , donde s_i es la puntuación cruda (la probabilidad heurística de la clase 1) e $y_i \in \{0, 1\}$ es la etiqueta verdadera (*ground truth*).
- 2 Se ordenan los pares de calibración por su puntuación s_i . Se agrupan las puntuaciones idénticas en valores únicos x_j , y para cada uno se calcula:

El peso w_j (número de ocurrencias),

La etiqueta media $\bar{y}_j$,

La suma acumulada de etiquetas ponderadas $C_j = \sum_{k \leq j} w_k \bar{y}_k$,

El peso acumulado $K_j = \sum_{k \leq j} w_k$.
- 3 Se construyen las envolventes convexas «superior» e «inferior»
Se forma el conjunto de puntos $P = \{(K_j, C_j)\}_{j=1}^J$.

Se obtiene la «cadena superior» F_1 hallando el mayor minorante convexo de $P \cup \{(0,0)\}$.

Se obtiene la «cadena inferior» F_0 hallando el menor mayorante cóncavo de $P \cup \{(K_J + 1, C_J)\}$.

- 4 A partir de las envolventes obtenidas se definen dos funciones no decrecientes:

$$F_1: [0, K_J] \rightarrow [0, 1], \quad F_0: [0, K_J] \rightarrow [0, 1],$$

que asocian peso acumulado a masa acumulada de etiquetas calibradas.

- 5 Se calculan los límites para cada puntuación de prueba:

Para cada objeto de prueba con puntuación cruda s , encuentra el intervalo de rango $[j_{\min}, j_{\max}]$ correspondiente en las puntuaciones únicas calibradas.

Se define $p_0 = F_0(j_{\min})$, $p_1 = F_1(j_{\max})$, lo que produce un intervalo de predicción válido $[p_0, p_1]$.

- 6 Como paso opcional, se colapsa a una estimación puntual:

Si se requiere un único valor para la toma de decisiones, convierte $[p_0, p_1]$ en una probabilidad puntual, por ejemplo:

$$p_{\text{mid}} = \frac{p_0 + p_1}{2}, \quad p_{\text{logloss}} = \frac{p_1}{1 - p_0 + p_1},$$

10.2 Librerías utilizadas

El trabajo se ha realizado en ambiente de desarrollo Python 3.9. Versiones posteriores presentaron problemas de compatibilidad con algunas de las librerías utilizadas. El código de desarrollo se generó en notebooks Jupyter y todos los ejecutables, incluyendo el paquete de funciones auxiliares, puede consultarse en el repositorio del proyecto en GitHub: <https://github.com/ppimas-uoc/TFG---Inteligencia-Artificial>. La figura 32 muestra la estructura del mismo.

```
— carbon/           # Consumo de energía y emisiones de CO2 de los notebooks
— data/             # Conjunto de datos (en crudo)
— documentation/    # Documentación del proyecto
— Fase 2/           # Análisis exploratorio, modelado y XAI
— Fase 3/           # Cuantificación de la incertidumbre
— html notebooks versions/ # Versiones html estáticas de los notebooks
— xaiuq_functions   # Paquete de funciones auxiliares
```

Figura 32: Estructura del repositorio de código del proyecto

A continuación se listan las librerías utilizadas, paquetes y algoritmos utilizados:

CatBoost: <https://catboost.ai/>

Librería de código abierto para boosting de gradiente que maneja de forma nativa variables categóricas sin necesidad de codificación previa, optimizada para alta eficiencia y precisión en clasificación y regresión.

CodeCarbon: <https://codecarbon.io/>

Librería de código abierto en Python diseñada para medir y estimar la huella de carbono de procesos computacionales. Durante la ejecución de un programa.

DiCE (Diverse Counterfactual Explanations): <https://github.com/interpretml/DiCE>

Herramienta que genera múltiples contraejemplos para una instancia, indicando qué cambios mínimos en las características producirían una clasificación distinta, fomentando explicaciones de contraste.

Jupyter Notebooks: <https://jupyter.org/>

Entorno interactivo de código abierto que permite crear y compartir documentos que combinan código en vivo, texto explicativo, ecuaciones y visualizaciones. Facilita el análisis reproducible y la implementación de experimentos de ciencia de datos.

Matplotlib: <https://matplotlib.org/>

Librería de código abierto en Python para creación de gráficos 2D, con una API similar a MATLAB. Permite generar líneas, dispersiones, histogramas, barras y otras visualizaciones para análisis de datos.

Numpy: <https://numpy.org/>

Librería de código abierto en Python para cálculos numéricos eficientes sobre arreglos multidimensionales, que proporciona funciones matemáticas, herramientas de álgebra lineal y operaciones estadísticas.

LightGBM: <https://lightgbm.readthedocs.io/>

Librería de código abierto para boosting de gradiente desarrollada por Microsoft que utiliza un algoritmo basado en histogramas y crecimiento de árbol por hojas, optimizado para alta velocidad y bajo uso de memoria en tareas de clasificación y regresión.

LIME (Local Interpretable Model-agnostic Explanations): <https://github.com/marcotcr/lime>

Paquete que ajusta un modelo lineal interpretable alrededor de una instancia específica, usando muestreo local, para explicar la contribución de cada característica a esa predicción.

Pandas: <https://pandas.pydata.org>

Librería de código abierto en Python para manipulación y análisis de datos. Proporciona estructuras de datos como DataFrame y herramientas para leer, escribir, filtrar, transformar y resumir conjuntos de datos.

Seaborn: <https://seaborn.pydata.org/>

Librería de código abierto en Python construida sobre Matplotlib para visualización estadística, que ofrece gráficos de alto nivel como mapas de calor, distribuciones, relaciones entre variables y agregaciones con un estilo predeterminado mejorado.

Scikit-Learn: <https://scikit-learn.org>

Librería de código abierto en Python especializada en aprendizaje automático. Entre los algoritmos y modelos utilizados se encuentran:

KBinsDiscretizer

Transformador del módulo preprocessing de Scikit-Learn que convierte características continuas en discretas mediante la partición en un número fijo de intervalos (bins).

DecisionTree

Implementación de árbol de decisión que particiona recursivamente los datos según criterios de impureza (por ejemplo, índice Gini o entropía en clasificación, y reducción de varianza en regresión) para crear reglas de decisión interpretable.

RandomForest

Implementación de bosque aleatorio que combina múltiples árboles de decisión entrenados con muestreo con reemplazo (bagging) y selección aleatoria de características en cada división, reduciendo la varianza del conjunto y mejorando la capacidad de generalización.

GridSearchCV

Algoritmo de búsqueda de hiperparámetros que recorre exhaustivamente combinaciones de parámetros, aplicando validación cruzada para evaluar cada configuración y seleccionando aquella que optimiza la métrica objetivo.

PartialDependenceDisplay

Kind = average genera los Partial Dependence Plots:

Muestra cómo varían las predicciones promedio del modelo cuando cambia una característica, manteniendo las demás constantes, para interpretar efectos marginales globales.

kind = individual genera los Individual Conditional Expectation:

Traza la trayectoria de la predicción de una instancia mientras se varía una característica y las demás permanecen fijas, mostrando efectos individuales.

permutation_importance (Permutation Feature Importance):

Método agnóstico al modelo que calcula la pérdida de rendimiento (p. ej., F1-score) al desordenar aleatoriamente cada atributo, permitiendo evaluar su contribución global.

SHAP (SHapley Additive exPlanations): <https://shap.readthedocs.io/>

Librería de código abierto para cómputo de valores SHAP que ofrece gráficos globales (summary plot) mostrando la contribución media y la dispersión de cada variable en el conjunto completo.

XGBoost: <https://xgboost.ai/>

Librería de código abierto para boosting de gradiente optimizado que implementa regularización L1/L2, manejo eficiente de datos dispersos y paralelización, ofreciendo alto rendimiento y precisión en tareas de clasificación y regresión.

10.3 Diseño de alto nivel de la solución de un SI

El desarrollo de un sistema basado en el flujo de trabajo propuesto, a grandes rasgos, supone orquestrar cuatro capas de software bien diferenciadas pero interconectadas:

Capa de integración de datos (ETL/FHIR)

Un módulo que extraiga automática y periódicamente los PROMs y las variables clínicas relevantes desde el historial electrónico del hospital (EHR) —idealmente mediante el estándar FHIR—, los depure con reglas de calidad y los alimente al motor de inferencia.

Motor de inferencia y MLOps

El modelo Random Forest calibrado con IVAP (o la versión futura más robusta) se despliega como micro-servicio con APIs REST. Un pipeline de MLOps controla versiones, re-entrena cuando se incorporan nuevos datos multicéntricos y supervisa el drift; además, registra el intervalo de incertidumbre de cada salida para auditorías posteriores.

Capa de explicabilidad interactiva

Sobre el motor de inferencia se superpone un servicio de explicabilidad que exponga, en tiempo real, las visualizaciones SHAP y los contra-ejemplos DiCE. Estas explicaciones deben mostrarse en lenguaje clínico, evitando jerga técnica, e incluir alertas cuando la anchura del intervalo de probabilidad supere un umbral configurable.

Interfaz clínica (dashboard web)

Un panel que permita al oncólogo consultar la predicción y su intervalo de confianza para cada paciente; explorar los factores funcionales y sintomáticos que más influyen en la recomendación; simular escenarios hipotéticos para evaluar posibles intervenciones; y enviar feedback que se registre como etiqueta de validación, alimentando un ciclo de mejora continua.

La figura 32 muestra el diagrama asociado que incorpora una interfaz asistida por IA para ingresar la información de los PROMs por los pacientes.




Figura 33: Diagrama de capas de un SI para incorporar el flujo de trabajo