

75.629**TFG - Intel·ligencia Artificial**

| | |
|--------|--|
| Aula | 1 |
| PEC 0 | Definición de los contenidos del trabajo |
| Alumno | Pablo Pimàs Verge |
| Fecha | 27/02/2025 |

Aplicación de técnicas de IA fiable en la predicción del índice de calidad de vida (QoL) en pacientes de cáncer mediante aprendizaje automático.

Keywords

trustworthy AI, quality of life in cancer patients, patient-centered healthcare, QoL, machine learning in oncology, EORTC QLQ-C30, EORTC QLQ-C23, interpretable machine learning, counterfactual explanations, clinical decision support, explainability, uncertainty quantification, artificial intelligence in oncology, European AI Act, WHOQOL, ethical AI, PROMs, patient-reported outcomes, personalized medicine.

Índice

| | | |
|----|-------------------------|---|
| 1. | Temática y motivación | 2 |
| 2. | Problemática a resolver | 2 |
| 3. | Objetivos | 3 |
| 4. | Bibliografía | 4 |

1. Temática y motivación

En los últimos años, los gobiernos han reconocido la importancia de orientar los sistemas sanitarios hacia un enfoque centrado en las personas. Un ejemplo de este compromiso es la encuesta de Indicadores Referidos por los Pacientes (PaRIS, por sus siglas en inglés), impulsada globalmente por la Organización para la Cooperación y el Desarrollo Económicos (OCDE), en la que España participa activamente¹.

En este contexto, la Organización Europea para la Investigación y el Tratamiento del Cáncer (EORTC, por sus siglas en inglés) ha desarrollado el cuestionario EORTC QLQ-C30² que se ha posicionado como un estándar para calcular la percepción de los pacientes de su calidad de vida durante el tratamiento del cáncer.

La investigación emergente sobre los patrones psicofísicos que influyen en la relación entre la experiencia existencial de los pacientes en tratamiento y el éxito terapéutico está abriendo nuevas posibilidades. Liu et al. (2022)³ exploraron este enfoque mediante algoritmos de árboles aleatorios para predecir la disminución del QoL en pacientes con cáncer de tiroides. Sus resultados no solo evidencian la precisión de estas técnicas en la identificación del deterioro de la calidad de vida, sino que también plantean la posibilidad de trasladar este conocimiento a la práctica clínica.

Por otra parte, El Reglamento (UE) 2024/1689 sobre Inteligencia Artificial (AI Act)⁴ establece criterios estrictos para el uso de IA en aplicaciones médicas, imponiendo requisitos de transparencia, seguridad y explicabilidad para que los modelos sean auditables y sus decisiones comprensibles. Además, exige mecanismos de gestión de la incertidumbre para minimizar sesgos y errores en las recomendaciones automatizadas, como se refleja en las Recomendaciones Éticas para una IA Fiable (AI HLEG, 2019)⁵.

En conclusión, para que los sistemas desarrollados sean adoptados en entornos clínicos reales, es imprescindible que los modelos sean fiables. Deben cumplir aspectos críticos como la explicabilidad y la cuantificación de la incertidumbre. La primera es fundamental para que los profesionales sanitarios comprendan cómo un modelo llega a sus predicciones, facilitando su integración en la toma de decisiones médicas. La segunda permite evaluar la confianza en las predicciones del modelo.

2. Problemática a resolver

Una de las principales limitaciones en la práctica clínica oncológica es la falta de herramientas que permitan a los médicos convertir los datos sobre calidad de vida en

acciones concretas para mejorar el bienestar de los pacientes. Fayers y Bottomley (2002)⁶ destacan la complejidad de integrar la evaluación del QoL en ensayos clínicos, señalando desafíos como el manejo de datos incompletos, la interpretación de múltiples escalas en mediciones repetidas y la variabilidad en el cumplimiento. Sin herramientas avanzadas para el análisis e integración de datos, la aplicación clínica de estos indicadores sigue siendo limitada.

En este contexto, la función de los modelos generados será predecir el índice QoL para determinar la viabilidad de resolver la problemática planteada: ¿Es posible crear un sistema de predicción del QoL que permita dar apoyo a los profesionales médicos para mejorar la calidad de vida de los pacientes?

3. Objetivos

El objetivo es desarrollar un modelo de clasificación multiclase del índice QoL mediante algoritmos de aprendizaje automático supervisado. Se aplicarán herramientas de IA fiable en dos aspectos: explicabilidad para determinar la relación y los patrones subyacentes entre las variables calculadas del EORTC QLQ-C30 y el índice QoL; y cuantificación de la incertidumbre para interpretar el modelo y determinar su fiabilidad. En consecuencia, el trabajo se propone alcanzar los siguientes hitos:

1. Desarrollar un modelo de aprendizaje automático supervisado de clasificación multiclase optimizado.
2. Estudiar el marco de referencia de IA fiable para determinar la aplicación de las herramientas apropiadas y el cumplimiento de las recomendaciones de la Unión Europea.
3. Aplicar las herramientas de IA fiable para explicar las predicciones obtenidas y cuantificar su confiabilidad.
4. Incorporar modelos contrafactuales para identificar los cambios mínimos necesarios en las variables del modelo que permitan mejorar la predicción.
5. Extraer conclusiones de los resultados obtenidos y discutir la aportación y limitaciones del modelo para resolver la problemática planteada.

El trabajo se llevará a cabo utilizando un conjunto de datos tabulares y etiquetados, compuesto por 1.717 observaciones, cuya variable objetivo es el QoL, representada como un valor decimal discreto con distribución normal. Estos datos, compartidos por

Pimrapat Gebert en Mendeley Data⁷, provienen de una encuesta basada en el EORTC QLQ-C30 aplicada a pacientes con cáncer de mama en el hospital Charité Universitätsmedizin Berlin.

Para la consecución de los objetivos se utilizarán librerías y herramientas en el *stack* del lenguaje Python y se establecen las siguientes acciones específicas:

1. Realizar un análisis exploratorio de datos del conjunto a utilizar.
2. Desarrollar y comparar modelos de clasificación basados en algoritmos de árboles de decisión con técnicas de *bootstrap aggregating* (Random Forest y Extra Trees) y boosting (XGBoost, LightGBM y CatBoost) .
3. Optimizar el umbral de decisión en los modelos.
4. Explicar las predicciones obtenidas con el modelo óptimo mediante SHAP y LIME.
5. Determinar la incidencia de las variables del modelo en la predicción mediante SHAP y Permutation Feature Importance.
6. Cuantificar la confiabilidad del modelo mediante técnicas de validación y calibración.
7. Aplicar modelos contrafactuales mediante DiCE.

4. Bibliografía

1. Zoni Matta, A.C., y otros (2023, 7 de septiembre). "Encuesta Internacional de Indicadores de Salud Referidos por los Pacientes: el protocolo del Estudio PaRIS en España". *Revista Española de Salud Pública* [documento en línea]. [Fecha de consulta: 25 de febrero de 2025]. <https://www.sanidad.gob.es/estadEstudios/estadisticas/PaRIS/docs/Protocolo_proyecto_PaRIS_Espana.pdf>
2. European Organisation for Research and Treatment of Cancer (EORTC). (s.f.). "Quality of Life Questionnaires". EORTC [página web]. [Fecha de consulta: 26 de febrero de 2025]. <<https://qol.eortc.org/questionnaires/>>
3. Liu, Y. H., Jin, J., & Liu, Y. J. (2022). "Machine learning-based random forest for predicting decreased quality of life in thyroid cancer patients after thyroidectomy". *Supportive Care in Cancer* (vol. 30, núm. 3, págs. 2507-2513). Springer. doi:10.1007/s00520-021-06657-0
4. EU Artificial Intelligence Act (s.f.). "The AI Act Explorer". [página web]. [Fecha de consulta: 27 de febrero de 2025]. <<https://artificialintelligenceact.eu/ai-act-explorer/>>

5. Grupo Independiente de Expertos de Alto Nivel sobre Inteligencia Artificial. (2019, abril). Directrices éticas para una IA fiable. Comisión Europea [documento en línea]. [Fecha de consulta: 27 de febrero de 2025]. <<https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>>
6. Fayers, P.; Bottomley, A. (2002). "Quality of life research within the EORTC - The EORTC QLQ-C30". European Journal of Cancer (vol. 38, supl. S125-S133). [Fecha de consulta: 27 de febrero de 2025]. <[https://doi.org/10.1016/S0959-8049\(01\)00448-8](https://doi.org/10.1016/S0959-8049(01)00448-8)>
7. Gebert, Pimrapat. (2023). Quality of Life (QoL) Dataset in Breast Cancer Patients Based on EORTC QLQ-C30 [conjunto de datos]. Mendeley Data, V4. [Fecha de consulta: 28 de febrero de 2025]. <<https://data.mendeley.com/datasets/wrhr5862cb/4>>